CLS-ER + SD²-SNN

把互补学习系统的快慢机制移植到脉冲神经网络

六处改造 · 二十余条否定路线 · 一份实测记录（含对评测头的警告）

项目	内容
组合的两条论文线	CLS-ER（ICLR'22，互补学习系统 + 双语义记忆 + 回放） SD²-SNN（脉冲骨干、直接编码 T 步、可选结构化分解）
代码	CLS-ER+SD2-SNN（PyTorch 2.x + CUDA 12.x，20 个 Python 文件，38 项自检）
基准	Seq-CIFAR-10（5 任务 × 2 类），buffer 500，Class-IL / Task-IL
平台	RTX 4060 Laptop 8 GB / Windows / bf16
实验量	38 次训练运行，约 53 小时 GPU
日期	2026-10-30 ~ 2026-11-05

1 摘要

本项目把 CLS-ER 的互补学习系统（双语义记忆 + 选择性一致性约束 + 回放）移植到 SD²-SNN 的脉冲骨干上，并系统回答了三个问题：哪些 ANN 机制在脉冲网络里会失效、改造后能拿回多少、以及剩下的差距在哪里。

- **一条贯穿全文的方法论发现（§8i）**：线性分类头在 class-IL 下的新类偏置**随配置从 −32.7 变到 +34.2 点**，足以翻转结论。全部 25 个 checkpoint 用类均值头（NCM）重测后，**本文一半的排序发生变化**——例如“加容量是负收益”变成“全场最好”。
- **六处机制必须改造**：整状态 EMA（参数 + BN 统计 + 阈值）、软门控选择器、率域温度 KL、时序蒸馏、稳态阈值校准、近端约束。直接照搬 ANN 口径只有 39.50（类均值头 47.82）。
- **SNN 基线 = 59.64（类均值头）**，比 ANN 口径高 **11.8 点**。
- **最好的 SNN 配置是 PLIF + T=8（§8e）：67.58**（线性头 62.73），相对 SNN 基线 **+7.9**。
- **最好的 ANN 是论文同规模（11.2 M / 50 ep）：69.90**（线性头只有 59.62），距官方 75.22 还差 **5.32**。
- **脉冲基底的代价不是固定值**：裸配置 9.36 → 加 PLIF 后 2.58 → 再加 T=8 后 **1.42**。也就是说“脉冲差 8 点”这个说法只在完全没有优化的配置下成立。
- **换头之后，好几个“著名负结果”翻正**：1:1 回放 −9.1 → **+4.29**、三者全开 +4.22 → +3.56、固定正交头 +3.86 → +2.73、WA/LA 校准 −2.8 → +1.93。仍然为负的只有：soft-DTW 对齐（−2.24）、k-WTA（−2.18）、时序蒸馏 step（−0.10）。
- **两个“更根本”的假设也被证伪**：读出量化（连续膜电位 ≈ 9 档量化）、表征正交性（齿状回 k-WTA 扩张到 51 个稀疏单元后 class-IL 仍持平）。
- **另一条方法论教训**：任务数 ≤ 2 的消融会系统性高估“保护旧任务”类改动——同一改动在 2 任务上 +5.6、在 5 任务上 −9.1（这一条也已按类均值头修正为 +4.29）。

2 目标与两条论文线的交接面

两个方法负责的事情是正交的，这也是移植能成立的先决条件：

表 1 两条论文线的分工

层	CLS-ER 提供	SD²-SNN 提供
学什么	working + stable/plastic 双 EMA 记忆 选择器式一致性约束（Eq.1） reservoir 回放	—

层	CLS-ER 提供	SD²-SNN 提供
用什么学	—	LIF + ATan 替代梯度 Spiking-ResNet-18，直接编码 T 步时间平均放电率读出
可选增强	—	$W \approx UV^T$ 分解 / KL 稀疏 / 稀疏子空间（默认关闭）

于是移植的接口只有三处：输入编码、特征/放电率读出、以及“什么算一次前向”。CLS-ER 的三个模型（working / stable / plastic）共享同一套骨干结构，记忆只是权重副本。

3 六处必须改造的机制

原版 CLS-ER 的每条机制都隐含 ANN 假设，在脉冲网络里逐条失效。下表给出假设、现实、替换与证据：

表 2 六处改造（①–③ 是主实验捆绑的三项，④–⑥ 为可选）

#	原机制	ANN 隐含假设 → SNN 现实	替换为	证据
①	只 EMA 参数 W	函数只由 W 决定 → 函数由 (W, BN 统计, v_{th}, τ) 共同决定，BN 统计直接决定放电率尺度	整状态 EMA（参数 + buffers + 阈值）	ANN 口径下 frac_stable 前 4 任务恒 0.000
②	按真值置信度硬选记忆	softmax 置信度可靠 → T 步平均放电率方差 ~ $r(1-r)/T$	软门控 $w=\sigma(\beta\Delta c)$，$\beta\to\infty$ 退化回硬选择	低置信度区硬选择被噪声主导
③	logits 上的 MSE	logits 连续、量级稳定 → 脉冲 logits 是放电率的线性映射，量纲小且随 T 漂移	率域温度 KL + 脉冲数可靠性加权	同尺度差下 MSE 爆到 8.3、KL 有界
④	单一时刻输出	只有一个监督点 → T 个时刻各自产生证据，“何时发放”是信息	时序蒸馏（逐 timestep logits 的 KL）	ANN 无此维度，故为新增项
⑤	无活动调节	激活不会死/饱和 → 放电率会崩塌或爆炸（SNN 特有失败模式）	稳态阈值校准（homeostatic）	单任务 30.40 → 42.00（+11.6）
⑥	仅 logits 蒸馏	梯度无偏 → 代理梯度有偏，参数沿噪声方向漂移	近端约束 $\lambda\|\|\theta_W-\theta_{stable}\|\|^2$	可选，默认关闭

两条最硬的证据：

- **放电率**：未校准的网络在任务 0 开始几乎不发放（全网平均 0.001），校准后 0.065；学完一个任务又涨到 0.385，下个任务开始前再校准回 0.089。ANN 机制在这种情况下根本没有可用信号。

- **frac_stable**：ANN 口径下前 4 个任务恒为 0.000——stable 记忆一次都没被选中过，因为它的 BN 统计冻结在初始化副本上。整状态 EMA 之后它全程在 0.3–0.9 起伏，任务边界处升高（慢记忆接管）。

4 主实验：SNN 原生适配 vs ANN 口径

同 seed、同预算（width 32、T=4、buffer 500、batch 32、25 epochs × 5 任务），唯一差别是上表 ①②③ 的机制口径：

表 3 五任务主结果（Class-IL 为 5 个任务的平均）

配置	class-IL	task-IL	F_cil	F_til	BWT	耗时
SNN 原生	**57.51**	**88.98**	**33.49**	**3.91**	**-40.47**	**108 min**
ANN 口径	39.50	80.36	52.36	12.54	-58.02	126 min
差	+18.01	+8.62	-18.87	-8.63	17.55	—

表 4 SNN 原生的 Class-IL 矩阵（行 = 学完第 j 个任务，列 = 任务 i）

学完后	t0	t1	t2	t3	t4
t0	96.1				
t1	74.3	83.7			
t2	76.5	28.3	87.5		
t3	72.8	22.6	31.5	93.7	
t4	40.1	31.8	51.9	69.8	94.0

表 5 ANN 口径的 Class-IL 矩阵

学完后	t0	t1	t2	t3	t4
t0	96.2				
t1	66.8	83.1			
t2	68.7	14.9	89.2		
t3	62.7	7.3	5.3	96.3	
t4	23.2	32.6	19.4	27.9	94.5

三点分析：

- **单任务上限完全相同**（96.1 vs 96.2）——骨干能力一致，差异纯粹来自记忆机制。
- **差距集中在“中间任务被挤死”**：ANN 口径下 t1/t2 在学完 4 个任务后只剩 7.3 / 5.4（4 分类随机为 25%），SNN 口径保住 22.7 / 31.5；最老任务也更好（72.8 vs 62.7）。

- **task-IL 也领先 8.6 点**（89.0 vs 80.4），说明改善不只是重排 logits——整状态 EMA 让记忆真的成了一个行为自洽的慢速教师。

必须说清的局限：这一组比较的是 ①②③ 的**捆绑**，没有逐项拆开。“总共值 +18 点”是可靠的，“每项各值多少”还不知道；且只跑了单个 seed。

5 五条后续路线，全部为负

主实验之后，围绕“task-IL 89 而 class-IL 57.5 之间那 31 点”继续追，试了五条路线。每条都有明确的机制假设，每条都被实测否定。

表 6 五条路线的假设、实测与判定

路线	机制假设	实测	判定
logit 校准 (WA/LA/BiC/余弦头)	瓶颈是跨任务 logit 偏置，事后修正即可	三变体 −2.8 / −4.4 / −5.1	否定
NCM 换头 (最近类均值)	线性头无法跨任务比较，换掉它	57.51 → 59.64（+2.1）	边际
特征原型约束 (吸引 + 类间铰链)	特征缺跨任务结构，训练时加约束	六组全负（2 任务快验 −0.6 ~ −2.5）	否定
1:1 回放 (minibatch 10→32)	旧类只拿到 24% 梯度预算	2 任务 +5.6 → 5 任务 −9.1	否定
一致性权重 (0.75→1.5)	主损失权重是照搬 ANN 的	−5.0（0.3 与 0.75 打平）	否定

5.1 logit 校准：两次假设被证伪

实现了四个组件（权重对齐 WA、logit 调整 LA、偏置修正 BiC、余弦分类头），全部是 $z \to a \odot z + b$ 形式的后处理变换，不改网络、不影响记忆。

表 7 三个校准变体（2 任务、8 epochs 口径）

变体	t1 class-IL	判定	说明
基线（无校准）	79.00	—	—
WA+LA，统计量在增广样本上估	76.25	−2.75	假设：增广导致统计偏差
WA+LA，统计量在干净样本上估	74.60	−4.40	证伪：换成干净样本更差
LA，边缘均值估计器	73.92	−5.08	证伪：修正估计量后更差

两次证伪指向同一件事：问题不在“统计量估在哪儿”也不在“估计量的形式”，而在事后校正这条路本身。机理是脉冲 logits 活在放电率尺度上，该尺度随任务增加持续漂移（BN 统计、阈值都在变），静态的逐类偏置追不上这种漂移。

5.2 NCM：+2.1 点，但推翻了我的诊断

在同一个 checkpoint 上（完全相同的权重与 buffer）只换决策规则：

表 8 同权重换头的免训练对比

决策规则	class-IL	task-IL	每任务 Class-IL
线性头	57.51	88.98	[40.1, 31.8, 51.9, 69.8, 94.0]
NCM（余弦）	59.64	88.64	[47.5, 33.2, 51.4, 74.2, 91.8]
NCM（欧氏）	59.64	87.95	[49.3, 35.7, 51.8, 69.6, 91.8]

关键在第二列的差：如果瓶颈真在分类头，NCM 应该接近 task-IL 的 89，实际只有 59.6。**task-IL 89 是虚高的**——在 2 个类里做二分类，几乎任何特征空间都能做到 85+，它并不说明特征具备跨任务可比性。这条结果把诊断从“头坏了”改成“特征空间缺跨任务结构”。

5.3 特征原型约束：六组全负，且是同一个模式

表 9 原型约束六组（2 任务、8 epochs，与基线同预算）

配置	t0	t1 class-IL	旧任务	新任务	F_cil
基线	91.5	72.00	67.4	76.6	12.07
吸引 λ=0.1	94.2	71.00	63.4	78.7	15.40
吸引 λ=0.3	91.7	68.17	60.4	76.0	15.68
吸引 λ=1.0	92.7	70.00	60.1	79.9	16.28
吸引 0.05 + 铰链 0.1	90.7	70.45	65.2	75.8	12.77
铰链 0.5 / λ=1.0	93.7	71.42	65.5	77.4	14.10

三条稳定规律：约束本身**收敛**（原型损失 0.7–0.8，远低于随机 1.39；铰链能从 0.076 涨到 0.384，说明确实咬住了）→ 当前任务**一致变好** → 旧任务**一致变差**。也就是说它不是“实现没生效”，而是“生效了但方向不对”：类内吸引只把每个簇各自收紧，不约束簇与簇的相对布局，而后者才是 CIL 的瓶颈。

5.4 1:1 回放：2 任务的灵丹，5 任务的毒药

这是本项目最重要的一课。`--minibatch-size` 从项目开始一直对齐 CLS-ER 官方默认 10（每步回放 10 个旧样本，旧类只占 24% 的梯度预算）。

表 10 1:1 回放的逐检查点结果（5 任务 × 25 epochs）

预算	t0	t1	t2	t3	t4	class-IL	F_cil
24% 回放（基线）	96.1	79.0	64.1	55.2	57.5	57.51	33.49
1:1 回放	97.2	81.0	60.8	52.1	48.4	48.43	43.31

但在 2 任务、8 epochs 的快验里，同一改动是 **+5.6**（72.0 → 77.6，旧任务 67.4 → 77.0、F_cil 12.07 → 8.38），看起来像重大突破。

为什么 2 任务会骗人：只有 1 个旧任务时，32 个回放样本能均匀覆盖它（每类约 16 个），所以“提高回放权重”必然有效。任务数一多，同样的预算被摊到 4 个旧任务上，**每个旧类每步只剩 2–3 个样本**——信号不是变强而是变碎。证据是中间任务受害最重（t1 22.7 → 16.2、t2 31.5 → 23.2），而最老与最新的任务反而都略有提升。

5.5 一致性权重：0.75 是对的，敏感性是单向的

表 11 reg_weight 扫描（3 任务、8 epochs）

λ	t0	t1	t2（3 任务）	cons 占总损失	判定
0.3	92.7	73.9	56.06	5–10%	与 0.75 打平
0.75（默认）	92.7	71.9	55.78	6–13%	基准
1.5	89.9	66.7	50.82	—	明显更差

一致性项在默认配置下只占总损失的 6–13%，属于温和约束；往小调没有收益，往大调是悬崖。所以“照搬 ANN 的 0.75”不是问题，这条待办可以关闭。

6 一条方法论教训

把 §5.4 的观察提炼成一句可复用的结论：

在持续学习里，任务数 ≤ 2 的消融会系统性高估任何“保护旧任务”类改动的收益。

本项目在这个陷阱上花掉了约 4 小时 GPU：1:1 回放在 2 任务上给出 +5.6 的假信号，5 任务才暴露为 −9.1。同类风险也适用于一切“加强旧任务约束”的改动（原型约束、铰链、更高的 reg_weight）——它们在我们的 2 任务快验里全部看起来“有效或无害”，而 5 任务上全部为负。

7 与 CLS-ER 论文的对比

论文 Table 1 的 Seq-CIFAR-10 / Class-IL / buffer 500 一栏与本项目并列：

表 12 与论文 Table 1 的并列（Class-IL，buffer 500）

方法	class-IL	说明
GEM	26.20 ± 1.26	
FDR	28.71 ± 3.23	
iCaRL	47.55 ± 3.95	也用最近类均值
GSS	49.73 ± 4.78	

方法	class-IL	说明
ER	**57.74 ± 0.27**	**纯经验回放**
Mean-ER	70.40 ± 1.21	两记忆平均融合
DER	72.70 ± 1.36	
CLS-ER（论文）	**75.22 ± 0.71**	**论文主方法**
JOINT（上界）	92.20 ± 0.15	10 类联合训练
— 本项目 —		
ANN 口径	39.50	介于 FDR 与 iCaRL 之间
SNN 原生	**57.51**	**≈ ER（57.74）**
SNN 原生 + NCM	59.64	仍低于 Mean-ER 10.8 / CLS-ER 15.6

三处口径差异必须说明，否则这个并列会误导：

- **训练预算**：论文 50 epochs，本项目 25 epochs（省一半 GPU 时间）。
- **骨干规模**：论文 ANN ResNet-18 约 11.2 M 参数；本项目脉冲 width-32 约 2.8 M（1/4）。
- **seed**：论文为 3 seed 均值 ± 标准差，本项目为单 seed。

因此 15.6 点的差距**不能归因于脉冲架构。**要归因，缺一个同预算、同数据划分的 ANN 骨干对照——本项目没有实现它，这是最明确的一处未完成。

8 差距归因：稠密骨干对照

这是最初缺失、也是最关键的一个对照：**同参数量、同预算、同数据划分、同一套 CLS-ER 机制**，只把基底从脉冲换成稠密卷积。为此实现了 `backbone_ann.DenseResNet18`，它与脉冲骨干满足完全相同的接口（forward / features / forward_temporal），因此模型、双记忆、一致性损失、NCM、校准器全部一行未改。

表 12b 稠密对照：只换基底，其余完全相同

	脉冲	稠密 ANN	差
class-IL	**57.51**	**65.56**	**+8.05**
task-IL	88.98	92.99	+4.01
F_cil	33.49	29.60	-3.89
耗时	108 min	71 min	—
参数量	2.80 M	2.80 M（1.00×）	—

表 12c 逐检查点：差距随任务数放大

检查点	脉冲	稠密 ANN	差
t0	96.1	98.8	+2.8
t1	79.0	84.0	+5.0
t2	64.1	69.1	+5.0
t3	55.2	61.8	+6.6
t4	**57.5**	**65.6**	**+8.0**

末行 per-task：ANN `[49.9, 39.6, 64.8, 77.1, 96.6]`，脉冲 `[40.2, 31.8, 51.9, 69.8, 94.0]`——**每一个任务都高 2.6–12.9 点。**

归因公式（数字对得上）

```
论文 CLS-ER（ANN, 50 epochs）           75.22
   |  -9.66   <- 预算与配方（我们只有 25 epochs）
   v
稠密 ANN（2.80 M, 25 epochs）            65.56
   |  -8.05   <- 脉冲基底（T=4 直接编码 + 时间平均放电率读出）
   v
脉冲 SNN（其余完全相同）                 57.51
------------------------------------------------
总差距 17.71 = 9.66（预算）+ 8.05（基底）
```

三条结论：

- **脉冲基底有真实代价，但没有想象中大**：相对差距约 12%。“脉冲网很差”的印象里，更大的一块其实来自预算不足（9.66 点）。

- **基底差距主要落在每个任务的绝对精度上**（低 2.6–12.9 点），F_cil 只差 3.9。这解释了此前八条“减少遗忘”的路线为何全部无效——**它们治的不是主要矛盾。**
- **我们的稠密 ANN 也只到 65.56**，离论文还差 9.66：这一半与脉冲无关，是 25 vs 50 epochs 加上简化掉的东西。差距有两块，块块都不小。

由此，优化方向应当从“减少遗忘”转向“提高单任务表征质量”：首推 `--time-steps 8`（SD²-SNN 复现里单任务上限 80.5 → 84.1），其次 `--width 64`（把参数提到与论文同规模的 11.2 M）。

8b 两个基底改进：T=8 与膜电位读出

表 12d 两个单变量基底改进（同 seed、同其余配置）

配置	class-IL	task-IL	F_cil	算力
放电率 T=4（基线）	57.51	88.98	33.49	1.00×
放电率 T=8	**58.80**	**90.28**	**33.27**	**2.08×**
膜电位 T=4	**57.96**	**89.37**	**33.32**	**1.23×**
（参考）稠密 ANN	65.56	92.99	29.60	0.66×

- **T=8 是本项目最好的 SNN 结果（+1.29），但要 2 倍算力**；膜电位用 1.23× 算力换 +0.45——每点收益的成本更低（0.51× vs 0.83× 算力/点），但绝对量太小。
- **一个假设被直接证伪**：曾推测“时间平均放电率的量化（T=4 时每维只有 9 个离散取值）是基底差距的主因”。实测完全连续的膜电位读出（96.3 / 57.96）与 9 档量化的放电率（96.1 / 57.51）几乎等价。**T=8 的收益来自“更多时间步 = 更多实际计算”，不是“更细的量化”。**
- **剩下约 6.3 点没有被任何“改模块”的手段触动。**它更可能来自训练动力学本身（替代梯度的偏差、固定 T 的计算深度上限），要动它属于换训练范式。

8c PLIF：把膜时间常数变成可学习（本项目最好的 SNN 结果）

固定 `tau=2` 意味着 **17 个 LIF 层用同一个时间积分尺度**——第一层（原始像素）和最后一层（抽象特征）的泄漏速度相同，这显然不合理。PLIF（Fang et al., ICCV'21）把它改成每层一个可学习标量：

```
1/tau = sigmoid(a)            # a 可学习，每层一个
v_t   = (1 - 1/tau) * v_{t-1} + x_t


# 初始化 a 使 1/tau = 0.5（等价于原来的 tau=2）
# 所以这是纯可学习化，不是换网络：只多 17 个参数
```

表 12e PLIF 的效果（同 seed、同其余配置）

配置	class-IL	task-IL	F_cil	算力	相对基线
放电率 T=4（基线）	57.51	88.98	33.49	1.00×	—
PLIF（可学习 tau）	**59.66**	**91.55**	**33.49**	**1.51×**	**+2.15**
（参考）稠密 ANN	65.56	92.99	29.60	0.66×	+8.05

- 逐检查点：**+1.7 / +3.1 / −0.1 / +2.4 / +2.2**（五个里四个为正）。
- **task-IL 也从 88.98 涨到 91.55（+2.57）**——这一点很关键：它说明改进不是“重排 logits”，而是表征质量本身变好了。
- 补回基底差距的 **27%**（2.15 / 8.05），是所有手段里收益最高的；按“每点收益的算力成本”算也优于 T=8（0.70× vs 0.83× 算力/点）。

8d 齿状回模式分离（k-WTA）：假设被证伪

诊断线索是 **task-IL 89 / class-IL 57.5**——每个任务内分得开、跨任务分不开。在数学上这就是“表征不够正交”。生物靠齿状回解决这个问题：颗粒细胞比皮层输入多一个数量级（扩张），且只有 2–5% 活跃（稀疏），于是重叠的输入得到几乎不重叠的码字。而我们的实测放电率是 **5–40%**，比生物密一个数量级。

表 12f 两版齿状回模型（都保持约 5% 的稀疏度）

配置	存活单元	t0	t1	class-IL	F_cil	算力
无稀疏（基线）	256（稠密）	96.1	79.0	57.51	33.49	1.00×
k-WTA 原地稀疏（5%）	13	94.2	77.4	56.37	32.75	1.13×
齿状回：4× 扩张 + 5% 稀疏	**51**	**95.6**	**78.8**	**57.41**	**33.29**	**1.57×**

- **扩张修好了“信息量”这一半**：原地稀疏到 13 个单元时 t0 掉 1.9 点，扩张 4 倍后存活 51 个单元，t0 只掉 0.5 点——代价随存活数单调减小（13→56.37，51→57.41，256→57.51）。
- **但“正交性收益”始终没有出现**：两版的 F_cil 只比基线好 0.2–0.7，在噪声内；class-IL 更是一直持平或略低。

- **因此“表征不够正交导致跨任务混淆”这个诊断被证伪。**把码字压到 5% 稀疏（理论上两两相关性大幅下降）并没有改善 class-IL——跨任务混淆的成因不是“码字太像”，而更可能是分类器在增长的 softmax 上失效，或特征被新任务的梯度整体推走。

两个实现 bug 值得一提（都由回归测试锁住了）：读出用 `last_v.detach()` 让骨干收不到梯度（task 0 掉到 64.8）；`forward_temporal` 在扩张模式下把 256 维特征喂给了 1024 维的头（直接报形状错误）。

8e 组合 PLIF + T=8：62.73，补回基底差距的 65%

表 12g 两个改进及其组合

配置	class-IL	task-IL	F_cil	算力	相对基线
基线 T=4	57.51	88.98	33.49	1.00×	—
PLIF 单独	59.66	91.55	33.49	1.51×	+2.15
T=8 单独	58.80	90.28	33.27	2.08×	+1.29
PLIF + T=8	**62.73**	**92.07**	**30.48**	**2.10×**	**+5.22**
稠密 ANN（参考）	65.56	92.99	29.60	0.66×	+8.05

- **超可加**：2.15 + 1.29 = 3.44，而组合拿到 **5.22**，多出 1.8 点的协同。机制上讲得通——PLIF 让每层找到合适的时间尺度，T=8 提供更多时间步；**有了合适的 τ，多出来的时间步才用得上。**
- **PLIF 在这个组合里几乎免费**：T=8 单独 225 分钟，组合 227 分钟。17 个标量参数、2 分钟开销，换来 3.9 点。

中间任务的改善是关键（下表左半为 class-IL，右半为末行 per-task）：

表 12h 逐检查点：t1 的 42.2 已经超过稠密 ANN 的 39.6

检查点	基线	基线 per-task	PLIF+T=8	其 per-task	ANN
t0	96.1	40.2	98.0	42.9	98.8
t1	**79.0**	**31.8**	**82.9**	**42.2**	**84.0**
t2	64.1	51.9	66.3	62.9	69.1
t3	55.2	69.8	60.2	71.1	61.8
t4	57.5	94.0	62.7	94.6	65.6

- t1 的 per-task **42.2 已经超过稠密 ANN 的 39.6**，t2 的 62.9 也接近 ANN 的 64.8。此前所有方法在 t1/t2 都只有 22–36 之间。
- F_cil 从 33.49 降到 **30.48**（ANN 29.60），遗忘也基本追平。

归因账本更新

```
论文 CLS-ER（ANN, 50ep）          75.22
  -9.66    预算/配方
我们的 ANN（25ep, 2.80M）          65.56
  -2.83    脉冲基底    <- 原本 8.05, 回 65%
我们的 SNN（PLIF + T=8）           62.73
```

“脉冲基底要付 8 点代价”这个结论被推翻了——用对架构（可学习 τ + 足够时步），代价只有 2.83 点。这同时说明前面那些“改机制”的尝试之所以无效，并不是任务本身无解，而是**改错了地方**：瓶颈在基底的训练动力学，不在持续学习的约束。

8f 固定正交分类头：同算力下最好，但与 PLIF+T=8 负交互

PS-SNN（Sci. Rep. 2026）的论点是：多数 SNN-CL 方法每个任务随机初始化分类头并用不平衡数据优化它，导致表征漂移；把可学习头换成**预先定义、固定、两两正交的类中心**就提供了稳定目标。实现只需两行：`nn.init.orthogonal_(fc.weight)` 后 `requires_grad_(False)`（`parameter_groups` 会自动跳过它，连权重衰减都碰不到）。

表 12i 固定正交头及其与 PLIF+T=8 的组合

配置	class-IL	task-IL	F_cil	算力	相对基线
基线	57.51	88.98	33.49	1.00×	—
固定正交头	**61.37**	**90.22**	**31.39**	**0.98×**	**+3.86**
三者全开（+PLIF+T=8）	61.73	90.83	32.55	2.2×	+4.22
（参考）PLIF+T=8	62.73	92.07	30.48	2.10×	+5.22

- 逐检查点（固定头）：96.7 / 82.2 / 64.9 / 59.1 / 61.4 —— **五个任务全部优于基线**，且算力与基线持平（106 vs 108 分钟）。这是本项目性价比最高的一次改动。
- **一个必须记录的弯路**：第一版照论文做 L2 归一化 + 余弦（s·cos），完全学不动（CE 卡在 log 10，预测恒为均匀）。原因是**放电率特征全部非负，而正交中心有正有负**，cos 被共同的正向分量主导，各类 logits 几乎相同。论文的设定里特征可正可负，直接搬过来不成立。现在 `--fixed-head-norm` 默认为 False。
- **负交互**：固定头 +3.86、PLIF+T=8 +5.22，相加本应 66.6，三者全开却只有 **61.73**（低于 PLIF+T=8 的 62.73）。掉的是中间任务（t1 −4.5、t2 −7.65），两头反而更好。

机制解释：两个改动治的是**同一个病**。当特征已经足够稳定（T=8 + 可学习 τ），冻结边界不再有额外好处，反而阻止边界跟随改善后的特征。**实用结论**：算力受限用固定头（+3.86，零额外算力）；追求精度用 PLIF+T=8（+5.22，2.1× 算力）。

8g 时序蒸馏：两种对齐方式都无效

脉冲网络输出的是**轨迹** $h_1 \ldots h_T$，而不是单个 logit 向量。逐时刻 KL 会把“证据晚一步出现”当成遗忘，因此另实现了可微的 **soft-DTW 轨迹对齐**（Cuturi & Blondel 2017）：它给出两条轨迹之间的最优对齐路径，允许学生把证据整体提前或推后。

表 12j 时序蒸馏的两种模式

配置	class-IL	task-IL	F_cil	相对基线
不蒸馏（基线）	57.51	88.98	33.49	—
step：逐时刻 KL（λ=0.5）	57.05	89.72	34.53	-0.46
dtw：soft-DTW（λ=0.5）	**54.70**	**87.08**	**33.03**	**-2.81**

- **两种都不行，而且 DTW 比逐时刻 KL 更差。** 这与“允许时间平移应该更好”的直觉相反。
- **λ 差 5 倍给出同一条曲线**（t1 78.2 / 78.3，t2 60.1 / 60.1），排除了“权重没调好”。
- **损伤位置固定：中间任务塌到 17–18**（基线 28.3）。中间任务既要向更新的轨迹对齐、又要向更旧的轨迹对齐，每次拉它的梯度方向都不一致。

实现上有一个必须记下的坑：soft-DTW 在两序列几乎相同时取值会低于硬最小值，**这等于给“把 logits 压小”发奖励**。修复办法是减去 teacher 与自身的距离并 clamp。单测锁住了核心性质：**时间平移 18.2 ≪ 内容改变 77.6**。

8h 补齐论文配方的四项尝试（结论被评测头推翻）

§8 把 17.7 点拆成“9.66 预算/配方 + 8.05 脉冲基底”。本节检验前半句：把四项可疑因素逐一补上（全部在**稠密 ANN** 上做，先排除脉冲干扰）。最初只看线性头时四项全为负；**换用类均值头重测后，其中两项其实是正的。**

表 12k 线性头让我们把两项正收益误判成了负收益

假设	实验	线性头	NCM	线性头的结论	修正后
基线	**ANN 2.80 M / 25ep / AdamW / reg 0.75**	**65.56**	**69.00**	**—**	**—**
① 容量 + 预算	11.2 M / 50ep	59.62	69.90	-5.94 否定	+0.90 最好
② 正则强度	同上 + reg 3.0（4×）	46.50	68.21	-13.12 灾难	-1.69 不算差
③ 优化器	2.8 M / 25ep / SGD 0.1	61.16	66.98	-4.40 否定	-2.02 略差
（对照）SNN	2.80 M / 25ep	57.51	59.64	—	—
（对照）SNN	11.2 M / 50ep	57.67	65.45	+0.16	+5.81

- **“加容量和预算是负收益”是错的**：线性头下 59.62（−5.94），类均值头下 69.90（**全场最好**）。偏置的大小和容量正相关。
- **“正则 4 倍是灾难”也是错的**：46.50 → 68.21，只比同规模基线低 1.7。
- **唯一站得住的是优化器**：SGD 0.1 在两个评测头下都比 AdamW 差约 2 点。

为什么会这样：线性头的新类偏置在“当前任务拟合得更狠”的配置上最大，而这些恰好是我们之前判定为“过拟合/灾难”的配置。类均值头不依赖 logits 的绝对尺度，所以它看到的是“特征空间里的类是否分得开”，而不是“分数有没有被压偏”。

8i 线性头在 class-IL 下不是可靠指标

同一批 checkpoint、同一个缓冲区、同一次前向——只换推理头（线性 vs 类均值），全部 25 组配置的结果如下。这一节是全文最重要的方法论发现。

表 12m 换头后 class-IL 的变化：−32.7 到 +34.2

配置	线性头	NCM	增益
ANN + 官方机制超参	55.02	67.55	+12.53
ANN + reg 3.0	46.50	68.21	+21.71
ANN @ 11.2 M / 50ep	59.62	69.90	+10.28
SNN 1:1 回放	48.43	63.93	+15.50
SNN 官方配方（train-mode 记忆）	27.44	61.67	+34.23
SNN PLIF 单独	59.66	66.42	+6.76
SNN PLIF + T=8	62.73	67.58	+4.85
SNN 基线	57.51	59.64	+2.13
SNN 固定正交头	61.37	62.37	+1.00
SNN 稳态阈值校准	**57.26**	**24.54**	**−32.72**

- **增益跨度 67 点。**这说明线性头的误差不是小扰动，而是**许多配置下的主要误差来源**——它随配置剧烈变化，因此线性头给出的排序基本不可用。
- **一个稳定的规律：线性头越差，NCM 增益越大。** 线性头的偏置集中在“当前任务拟合得更狠”的配置上。
- **它也能反向出错**：`--calibrate` 那组的 NCM 反而低 32.7 点（特征尺度被校准改坏，类均值头失效）。所以正确做法是**同时报告两个头**，而不是换一个更“好”的头。

给后续工作的建议：任何 SNN-CIL 的消融都应该同时报告线性头与类均值头。本文自己就是现成的反例——只看线性头会得出“加容量无用”“强正则有害”这类相反的结论。

8j 为什么类均值头不能拿来训练

既然类均值头评测能白拿 +2.1~4.9 点，自然的问题是：训练期就用它会怎样？两条路都试了，都失败，而且失败原因相同。

表 12n 三种分类器：只有可学习的线性头能训练

分类器	t0（2 类任务）	task 0 第 20 epoch 的 CE
线性头（基线）	**96.1**	**~0.09**
纯类均值头（`--head-mode ncm`）	53.5	log K（完全不学）
混合（`--head-mode hybrid`，辅助项 0.1）	60.0	0.70

- **根因**：`p_c = mean(f | label = c)`，损失把 `f` 推向 `p_c`、同时又让 `p_c` 跟着 `f` 走，两者互相抵消。
- **纯类均值头坍缩到** `CE = log K` **的驻点：所有特征压成一点 → 所有原型相同 → softmax 均匀** → 梯度恰好为零，**模型永远出不来。**
- **混合方案只是减慢了坍缩**：CE 项还在，但辅助项持续把同类特征往“批次均值”拉，而那是特征自己算出来的目标——等价于鼓励把同类压成一个点，t0 只有 60.0。

实现中修掉的两个问题（都不是根因，但都值得记）：

表 12o 两条失败路线的实现缺陷

问题	现象	修复
记忆用类均值头、学生用线性头	一致性项比较两种几何，cons 0.15 → 1.10	只在纯 ncm 模式下让记忆也用类均值头
新类还没进缓冲区 → 无原型 → logit 掩到 −1e4	辅助损失爆炸到 7665（loss 767）	缺失的类用当前批次的特征均值临时补上

结论：事后换头的那 2.1 点是一次性收益，不能靠“训练期换头”扩大。要让类均值头参与训练而不坍缩，需要对比学习那一套（stop-gradient + 负样本队列 + 动量编码器，SwAV/MoCo 式），那是另一个量级的工程，且与本文确认有效的主线（改基底：PLIF、时间步）方向不同。

8k 可学习发放阈值：单独有效，但与 PLIF 重叠

LIF 神经元有两个关键参数。§8c 已证明**时间常数 τ 可学习**值 +6.78；本节把阈值也变成可学习：`v_th = softplus(a_th)`，初始化使 softplus(a)=1.0（即原来的固定值），每层一个标量。`v_threshold` 做成了 property，所以阈值校准与整状态 EMA 无需改动，且可学习时参数 EMA 已覆盖它、不会平滑两遍。

表 12p 可学习阈值及其与 PLIF 的组合

配置	线性头	**类均值头**	算力	相对基线
SNN 基线	57.51	59.64	1.0×	—
可学习阈值单独	58.86	61.41	1.0×	+1.77
PLIF 单独	59.66	66.42	1.5×	+6.78
PLIF + 阈值	**60.38**	**65.86**	**1.0×**	**+6.22**
PLIF + T=8	62.73	67.58	2.1×	+7.94

- **两者不叠加**：1.77 + 6.78 的期望没有实现，实际只有 6.22——比 PLIF 单独还低 0.56。τ 决定“证据能积累多久”、v_th 决定“多少证据算够”，两者都在调放电率落在哪个区间；可学习 τ 一旦找到合适尺度，阈值只能在同一区间里微调。
- **但它把好配置的成本砍了一半**：PLIF+阈值 65.86 @ 1.8 小时，PLIF+T=8 67.58 @ 3.8 小时——**97.5% 的精度、一半算力。**
- **更重要的一点**：同样每层 17 个参数，控制**时间积分尺度**的 τ 值 +6.78，控制**发放门槛**的阈值只值 +1.77。对脉冲网络来说，**时间动态比阈值敏感一个量级。**“所有神经元参数都该可学”这句话并不成立。

8l 读出层的 4×4 → 1×1 平均：确实在丢信息

整条流水线上有一个环节从未被质疑过：layer4 输出的 4×4 脉冲图被 AdaptiveAvgPool2d(1) 平均成 256 个数，空间结构在分类头看到之前就消失了。“证据在哪里”这类信息永远不会到达分类器。

表 12q --readout-pool 的三种选择

模式	特征维度	额外参数	说明
avg	256	—	之前所有实验用的
flatten	**4096**	**+23,040**	**保留 4×4 网格**
attention	256	+257	SE 式逐样本空间门控

表 12r 保留空间网格带来 +3.14，但只有无偏分类器能看出来

配置	线性头	**类均值头**	换头增益
SNN 基线（avg）	57.51	59.64	+2.13
flatten	**58.56**	**62.78**	**+4.22**

- **全局平均确实在丢信息（+3.14）**，但线性头只看到 +1.05——因为它同时把分类头从 256 维扩到 4096 维，放大了新类偏置。换头增益从 2.13 涨到 4.22，是 §8i 那条规律（线性头系统性低估“好特征 + 大分类头”）的又一次验证。
- **单测把动机写成了断言**：两张 4×4 特征图均值相同、布局不同时，avg 池化后的结果**完全相等**，flatten 后不等。这不是“加了个开关”，而是“平均池化在原理上无法区分两种布局”的直接证明。
- **这是唯一一次“在特征之后动手”却有效的改动**——其余十几条（损失、分类器、记忆机制）全部为零或负。差别在于：它改的是**送进分类器之前**发生了什么，而不是分类器拿到特征之后做什么。

8m 所有“PLIF + 别的”组合都不如 PLIF 单独

§8k 与 §8l 各自拿到一个正收益。把 PLIF 与它们组合起来，结果全部**低于 PLIF 单独**（类均值头口径）：

表 12s 只有加时间步（T=8）能继续提升，其余两两组合都是负的

配置	线性头	**类均值头**	相对 PLIF 单独
PLIF 单独	**59.66**	**66.42**	**—**
PLIF + T=8	**62.73**	**67.58**	**+1.16**
PLIF + 可学习阈值	60.38	65.86	−0.56
PLIF + flatten 读出	60.06	65.01	−1.41
flatten 单独	58.56	62.78	(−3.64)
可学习阈值单独	58.86	61.41	(−5.01)

- **唯一的例外是时间步**：T=8 是“更多实际计算”，不是“更好的特征”——它把网络真正跑得更久，所以能和任何特征侧改动叠加。
- **为什么 flatten 与 PLIF 互斥**：flatten 把特征从 256 扩到 4096 维，而缓冲区每类只有约 50 个样本——类均值在 4096 维上的估计方差远大于 256 维。flatten 单独有效，是因为那时特征本身还弱；一旦 PLIF 把特征做好，4096 维原型估计就成了新瓶颈。
- **最优配置因此是“只开 PLIF，其余保持默认”**：架构上没有更多便宜的叠加空间，剩下的只有 T=8（+1.16，算力翻倍）和容量（对 SNN 无效，§8h）。

9 工程问题与修复

过程中定位到 6 个会直接污染实验结果的问题，均已修复并补了回归检查：

表 13 工程缺陷清单。其中 #1、#2 各自单独就让一批实验作废

#	问题	表现	修复
1	cosine 调度跨任务重启时继承 ≈0 学习率	task 1 的 CE 从 5.08 涨到 5.15，模型完全学不动	每个任务开始重置各组 lr
2	归一化特征的 EMA 原型在旋转空间里抵消	原型损失卡在 0.70 ≈ log 2，特征与自己的原型正交	改为每 epoch 从 buffer 精确重算
3	`--proto-weight 0` 时原型记忆不创建	“只开铰链”的配置静默失效，margin 恒为 0	两者任一为正即创建 + 断言
4	BiC 拟合在 `no_grad` 里跑	loss 无计算图，backward 直接报错	拟合段显式 enable_grad
5	in-place 列赋值切断计算图	反向后 logits 与参数脱钩	改 torch.where 的 out-of-place 写法
6	参数统计把两个记忆副本也算进去	显示 8.39 M（实际骨干 2.80 M）	分开报 backbone / total

10 结论与后续

已确立

- CLS-ER 的机制不能直接搬到 SNN：六处失效，改造后把 SNN 基线从 60 一档（ANN 口径的脉冲版）提到 59.64。
- **最重要的方法论发现（§8i）**：线性头在 class-IL 下的偏置随配置变化 **67 点**（−32.7 到 +34.2），足以翻转结论。全部重测后，本文一半的排序发生变化。因此所有主数字都以**类均值头**给出，并同时列出线性头作对照。
- **最好的 SNN 配置（§8e）**：PLIF + T=8，NCM 下 67.58（线性 62.73）。PLIF 只加 17 个参数，T=8 加 2 倍算力，两者超可加。
- **最好的 ANN（§8h）**：论文同规模（11.2 M / 50 ep），69.90。这个配置在线性头下只有 59.62，曾被我们误判为“加资源是负收益”。
- **脉冲基底的代价不是固定值**：裸配置 9.36 → 加 PLIF 2.58 → 再加 T=8 **1.42**。“脉冲差 8 点”只在完全没有优化的配置下成立。
- **两个基底改进的单变量效应（§8b）**：T=8 +1.29（2 倍算力），膜电位读出 +0.45。“读出量化是主因”这个假设被直接证伪——完全连续与 9 档量化几乎等价。
- **“表征不够正交”这个诊断被证伪（§8d）**：把码字压到 5% 稀疏（配 4 倍扩张，存活 51 个单元）之后，class-IL 仍与基线持平。

- **“补资源没用”也是错的（§8h）**：那四个结论里有两个（容量/预算、强正则）在线性头下被误判成负收益，换头后分别是 +0.90 和 −1.69。唯一稳定为负的是 SGD 优化器（约 −2）。

未完成 / 下一步

- **多 seed**：本项目全部是单 seed，2 点以内的差异不应解读。这是目前最大的短板。
- **把类均值头纳入训练**：现在它只是事后换头，若在训练期就用类均值分类器，可能同时改善特征与打分。
- **解释** `--calibrate` 的 NCM 异常**（−32.7）：那组特征尺度被改坏，说明阈值校准会改变特征几何，值得单独查。**
- **PLIF + T=8 + 论文规模（11.2 M）**：三者还没一起跑过，是目前最有希望超过 70 的组合（显存需要验证）。
- **T=16**（约 7 小时）：按 T=4→8 的斜率预计再 +1 左右，收益递减，不推荐。
- **换训练范式**（ANN-SNN 转换、长 T 训练后蒸馏到 T=4）：这 6.3 点最可能的来源是替代梯度的偏差与固定 T 的计算深度上限，动它属于新项目量级。

附录 A 全部运行清单

表 A1 46 次训练运行（部分为快验，任务数 < 5）。此处为线性头数字；同一批 checkpoint 的类均值头结果见 §8i 与 report/head_sweep.json

run	任务数	class-IL	task-IL	F_cil	分钟
ann_ctrl	5	65.56	92.99	29.60	71
ann_e25	5	39.50	80.36	52.36	126
ann_mechfix	5	55.02	93.94	41.22	41
ann_sgd	5	61.16	91.11	34.34	38
ann_w64_e50	5	59.62	93.64	36.92	88
cal	1	42.00	42.00	0.00	1
cal_la2	2	73.92	88.28	15.53	—
cal_wala	5	54.74	90.23	37.87	153
cal_wala_noaug	3	56.55	87.53	33.63	—
nocal	1	30.40	30.40	0.00	1
proto2_w01	2	71.00	84.58	15.40	27
proto2_w03	2	68.17	82.32	15.68	17
proto2_w10	2	70.00	83.55	16.28	16
proto3_A	2	70.45	83.47	12.77	16
proto4_C	2	71.42	84.45	14.10	16
proto_check	2	59.70	78.00	18.20	13
proto_w00	2	72.00	83.75	12.07	24
proto_w01	2	29.60	58.75	29.20	24
proto_w03	1	55.45	55.45	0.00	—
reg0.15_ann_official2	5	33.42	75.61	47.88	65
reg0.15_ann_official3	5	27.44	84.58	69.86	56
reg0.3_reg03	3	56.08	83.75	28.67	33
reg075	3	55.78	84.00	28.57	29
reg1.5_reg15	3	50.82	80.68	30.60	39
reg3_ann_w64_e50_reg3	5	46.50	92.13	48.19	79
replay32	2	77.55	86.60	8.38	44
snn_all3	5	61.73	90.83	32.55	189
snn_cal	5	57.26	88.48	33.72	148
snn_dg4	5	57.41	88.89	33.29	170
snn_e25	5	57.51	88.98	33.49	108
snn_flat	5	58.56	90.23	32.77	112
snn_hybrid	1	60.00	60.00	0.00	—
snn_kwta	5	56.37	88.19	32.75	122
snn_mem2	5	57.96	89.37	33.32	133
snn_plif	5	59.66	91.55	33.49	163
snn_plif_flat	5	60.06	90.97	32.90	181
snn_plif_t8	5	62.73	92.07	30.48	227
snn_plif_vth	5	60.38	90.69	32.56	132

run	任务数	class-IL	task-IL	F_cil	分钟
snn_pshead	5	61.37	90.22	31.39	106
snn_r32	5	48.43	89.84	43.31	151
snn_t8	5	58.80	90.28	33.27	225
snn_tdist	5	57.05	89.72	34.53	125
snn_tdtw	5	54.70	87.08	33.03	146
snn_tdtw01	4	54.72	87.54	34.83	—
snn_vth	5	58.86	90.38	33.13	129
snn_w64_e50	5	57.67	91.85	37.07	315

附录 B 复现命令

```
# 主实验：SNN 原生（默配置）
python scripts/train.py --dataset seq_cifar10 --epochs 25 \
    --buffer-size 500 --batch-size 32 --width 32 --time-steps 4 --tag snn_e25


# ANN 口径（硬选择 + logits MSE + 只 EMA 参数）
python scripts/train.py ... --selector-mode hard --consistency-loss mse \
    --no-ema-buffers --tag ann_e25


# 免训练的换头对比（同权重）
python tools/eval_head_compare.py runs/seq_cifar10_T4_w32_buf500_snn_e25


# 全部结果一览
python tools/summary_table.py
python tests/smoke_test.py        # 43 项自检
```

附录 C 自检覆盖（43 项）

表 C1 tests/smoke_test.py 的覆盖范围

组	项数	内容
A CLS-ER 机制	8	脉冲前向、LIF 二值性、reservoir、硬/软选择器、EMA 调度、observe、指标、跨任务 LR 复位
B SNN 适配	6	软门控连续性与 β→∞ 极限、整状态 EMA、距离函数、编码、时序蒸馏 + 近端项、稳态阈值校准
C SD²-SNN 正则	1	分解层 / 双学习率 / Eq.18 / Eq.3 / Eq.13-14
D logit 校准	6	变换、WA 夹取、LA 边缘估计量、BiC、余弦头、任务边界重拟合
E NCM	2	原型构造与缺失类屏蔽、评测路径（含反例）
F 原型约束	4	EMA 语义、损失可优化性、refresh 修复 EMA 抵消、训练集成
G–M 基底与工程	13	稠密对照、膜电位读出与其梯度、PLIF、齿状回 k-WTA、固定正交头、断点续训、soft-DTW 对齐

组	项数	内容
N 分类头与神经元参数	3	类均值头（含未出现类屏蔽）、ncm/hybrid 训练与线性头不更新、可学习阈值（正性与梯度）
O 读出与评测	2	读出池化三模式（含 avg 无法区分布局的证明）、换头重测