CLS-ER + SD²-SNN

把互补学习系统的快慢机制移植到脉冲神经网络

六处改造 · 二十余条否定路线 · 一份实测记录（含对评测头的警告）

项目	内容
组合的两条论文线	CLS-ER（ICLR'22，互补学习系统 + 双语义记忆 + 回放） SD²-SNN（脉冲骨干、直接编码 T 步、可选结构化分解）
代码	CLS-ER+SD2-SNN（PyTorch 2.x + CUDA 12.x，20 个 Python 文件，38 项自检）
基准	Seq-CIFAR-10（5 任务 × 2 类），buffer 500，Class-IL / Task-IL
平台	RTX 4060 Laptop 8 GB / Windows / bf16
实验量	38 次训练运行，约 53 小时 GPU
日期	2026-10-30 ~ 2026-11-09

1 摘要

本项目把 CLS-ER 的互补学习系统（双语义记忆 + 选择性一致性约束 + 回放）移植到 SD²-SNN 的脉冲骨干上，并系统回答了三个问题：哪些 ANN 机制在脉冲网络里会失效、改造后能拿回多少、以及剩下的差距在哪里。

- **核心结论（§10）：界线在“特征是怎么算出来的”和“特征之后做什么”之间。**四条正收益改动（可学习 τ、时间步、空间读出、可学习阈值）全部在改变**送进分类器之前**发生了什么；十几条零或负收益的改动（损失函数、分类头、记忆选择、校准）全部在改变**分类器拿到特征之后**做什么。
- **这些改动彼此替代而非互补**：PLIF+阈值 65.86、PLIF+flatten 65.01，都低于 PLIF 单独（66.42）。唯一能叠加的是时间步（T=8，+1.16），因为它是“真的多算”。
- **一条贯穿全文的方法论发现（§8i）**：线性分类头在 class-IL 下的新类偏置**随配置从 −32.7 变到 +34.2 点**，足以翻转结论。全部 27 个 checkpoint 用类均值头（NCM）重测后，**本文一半的排序发生变化**——例如“加容量是负收益”变成“全场最好”。
- **六处机制必须改造**：整状态 EMA（参数 + BN 统计 + 阈值）、软门控选择器、率域温度 KL、时序蒸馏、稳态阈值校准、近端约束。直接照搬 ANN 口径只有 39.50（类均值头 47.82）。
- **SNN 基线 = 59.64（类均值头）**，比 ANN 口径高 **11.8 点**。
- **最好的 SNN 配置是 PLIF + T=8（§8e）：67.58**（线性头 62.73），相对 SNN 基线 **+7.9**。
- **最好的 ANN 是论文同规模（11.2 M / 50 ep）：69.90**（线性头只有 59.62），距官方 75.22 还差 **5.32**。
- **脉冲基底的代价不是固定值**：裸配置 9.36 → 加 PLIF 后 2.58 → 再加 T=8 后 **1.42**。也就是说“脉冲差 8 点”这个说法只在完全没有优化的配置下成立。
- **两个“加在特征上”的正收益被单独确认**：保留 4×4 空间网格（不再全局平均）+3.14（§8l）——证明平均池化一直在丢信息；每层可学习发放阈值 +1.77（§8k）。
- **两条把分类器换成类均值头的训练路线都失败（§8j）**：纯类均值头坍缩到 `CE = log K` 的驻点（t0 = 53.5），混合方案只把 t0 拖到 60.0。原因相同——原型是特征的均值，损失把特征推向原型、原型又跟着特征走，目标函数自相矛盾。
- **换头之后，好几个“著名负结果”翻正**：1:1 回放 −9.1 → **+4.29**、三者全开 +4.22 → +3.56、固定正交头 +3.86 → +2.73、WA/LA 校准 −2.8 → +1.93。仍然为负的只有：soft-DTW 对齐（−2.24）、k-WTA（−2.18）、时序蒸馏 step（−0.10）。
- **两个“更根本”的假设被证伪**：读出量化（连续膜电位 ≈ 9 档量化等价）、表征正交性（齿状回 k-WTA 扩张到 51 个稀疏单元后 class-IL 仍持平）。

2 目标与两条论文线的交接面

两个方法负责的事情是正交的，这也是移植能成立的先决条件：

表 1 两条论文线的分工

层	CLS-ER 提供	SD²-SNN 提供
学什么	working + stable/plastic 双 EMA 记忆 选择器式一致性约束（Eq.1） reservoir 回放	—
用什么学	—	LIF + ATan 替代梯度 Spiking-ResNet-18，直接编码 T 步 时间平均放电率读出
可选增强	—	$W \approx UV^T$ 分解 / KL 稀疏 / 稀疏子空间（默认关闭）

于是移植的接口只有三处：输入编码、特征/放电率读出、以及“什么算一次前向”。CLS-ER 的三个模型（working / stable / plastic）共享同一套骨干结构，记忆只是权重副本。

3 六处必须改造的机制

原版 CLS-ER 的每条机制都隐含 ANN 假设，在脉冲网络里逐条失效。下表给出假设、现实、替换与证据：

表 2 六处改造（①–③ 是主实验捆绑的三项，④–⑥ 为可选）

#	原机制	ANN 隐含假设 → SNN 现实	替换为	证据
①	只 EMA 参数 W	函数只由 W 决定 → 函数由 (W, BN 统计, v_{th}, τ) 共同决定，BN 统计直接决定放电率尺度	整状态 EMA（参数 + buffers + 阈值）	ANN 口径下 frac_stable 前 4 任务恒 0.000
②	按真值置信度硬选记忆	softmax 置信度可靠 → T 步平均放电率方差 ~ $r(1-r)/T$	软门控 $w=\sigma(\beta\Delta c)$，$\beta\to\infty$ 退化回硬选择	低置信度区硬选择被噪声主导
③	logits 上的 MSE	logits 连续、量级稳定 → 脉冲 logits 是放电率的线性映射，量纲小且随 T 漂移	率域温度 KL + 脉冲数可靠性加权	同尺度差下 MSE 爆到 8.3、KL 有界
④	单一时刻输出	只有一个监督点 → T 个时刻各自产生证据，“何时发放”是信息	时序蒸馏（逐 timestep logits 的 KL）	ANN 无此维度，故为新增项
⑤	无活动调节	激活不会死/饱和 → 放电率会崩塌或爆炸（SNN 特有失败模式）	稳态阈值校准（homeostatic）	单任务 30.40 → 42.00（+11.6）

#	原机制	ANN 隐含假设 → SNN 现实	替换为	证据
⑥	仅 logits 蒸馏	梯度无偏 → 代理梯度有偏，参数沿噪声方向漂移	近端约束 $\lambda\|\|\theta_W-\theta_stable\|\|^2$	可选，默认关闭

两条最硬的证据：

- **放电率**：未校准的网络在任务 0 开始几乎不发放（全网平均 0.001），校准后 0.065；学完一个任务又涨到 0.385，下个任务开始前再校准回 0.089。ANN 机制在这种情况下根本没有可用信号。
- **frac_stable**：ANN 口径下前 4 个任务恒为 0.000——stable 记忆一次都没被选中过，因为它的 BN 统计冻结在初始化副本上。整状态 EMA 之后它全程在 0.3–0.9 起伏，任务边界处升高（慢记忆接管）。

4 主实验：SNN 原生适配 vs ANN 口径

同 seed、同预算（width 32、T=4、buffer 500、batch 32、25 epochs × 5 任务），唯一差别是上表 ①②③ 的机制口径：

表 3 五任务主结果（Class-IL 为 5 个任务的平均）

配置	class-IL	task-IL	F_cil	F_til	BWT	耗时
SNN 原生	**57.51**	**88.98**	**33.49**	**3.91**	**-40.47**	**108 min**
ANN 口径	39.50	80.36	52.36	12.54	-58.02	126 min
差	+18.01	+8.62	-18.87	-8.63	17.55	—

表 4 SNN 原生的 Class-IL 矩阵（行 = 学完第 j 个任务，列 = 任务 i）

学完后	t0	t1	t2	t3	t4
t0	96.1				
t1	74.3	83.7			
t2	76.5	28.3	87.5		
t3	72.8	22.6	31.5	93.7	
t4	40.1	31.8	51.9	69.8	94.0

表 5 ANN 口径的 Class-IL 矩阵

学完后	t0	t1	t2	t3	t4
t0	96.2				
t1	66.8	83.1			
t2	68.7	14.9	89.2		

学完后	t0	t1	t2	t3	t4
t3	62.7	7.3	5.3	96.3	
t4	23.2	32.6	19.4	27.9	94.5

三点分析：

- **单任务上限完全相同**（96.1 vs 96.2）——骨干能力一致，差异纯粹来自记忆机制。
- **差距集中在“中间任务被挤死”**：ANN 口径下 t1/t2 在学完 4 个任务后只剩 7.3 / 5.4（4 分类随机为 25%），SNN 口径保住 22.7 / 31.5；最老任务也更好（72.8 vs 62.7）。
- **task-IL 也领先 8.6 点**（89.0 vs 80.4），说明改善不只是重排 logits——整状态 EMA 让记忆真的成了一个行为自洽的慢速教师。

必须说清的局限：这一组比较的是 ①②③ 的**捆绑**，没有逐项拆开。“总共值 +18 点”是可靠的，“每项各值多少”还不知道；且只跑了单个 seed。

5 五条后续路线，全部为负

主实验之后，围绕“task-IL 89 而 class-IL 57.5 之间那 31 点”继续追，试了五条路线。每条都有明确的机制假设，每条都被实测否定。

表 6 五条路线的假设、实测与判定

路线	机制假设	实测	判定
logit 校准 (WA/LA/BiC/余弦头)	瓶颈是跨任务 logit 偏置，事后修正即可	三变体 −2.8 / −4.4 / −5.1	否定
NCM 换头 (最近类均值)	线性头无法跨任务比较，换掉它	57.51 → 59.64（+2.1）	边际
特征原型约束 (吸引 + 类间铰链)	特征缺跨任务结构，训练时加约束	六组全负（2 任务快验 −0.6 ~ −2.5）	否定
1:1 回放 (minibatch 10→32)	旧类只拿到 24% 梯度预算	2 任务 +5.6 → 5 任务 −9.1	否定
一致性权重 (0.75→1.5)	主损失权重是照搬 ANN 的	−5.0（0.3 与 0.75 打平）	否定

5.1 logit 校准：两次假设被证伪

实现了四个组件（权重对齐 WA、logit 调整 LA、偏置修正 BiC、余弦分类头），全部是 $z \to a \odot z + b$ 形式的后处理变换，不改网络、不影响记忆。

表 7 三个校准变体（2 任务、8 epochs 口径）

变体	t1 class-IL	判定	说明
基线（无校准）	79.00	—	—
WA+LA，统计量在增广样本上估	76.25	−2.75	假设：增广导致统计偏差
WA+LA，统计量在干净样本上估	74.60	−4.40	证伪：换成干净样本更差
LA，边缘均值估计器	73.92	−5.08	证伪：修正估计量后更差

两次证伪指向同一件事：问题不在“统计量估在哪儿”也不在“估计量的形式”，而在事后校正这条路本身。机理是脉冲 logits 活在放电率尺度上，该尺度随任务增加持续漂移（BN 统计、阈值都在变），静态的逐类偏置追不上这种漂移。

5.2 NCM：+2.1 点，但推翻了我的诊断

在同一个 checkpoint 上（完全相同的权重与 buffer）只换决策规则：

表 8 同权重换头的免训练对比

决策规则	class-IL	task-IL	每任务 Class-IL
线性头	57.51	88.98	[40.1, 31.8, 51.9, 69.8, 94.0]
NCM（余弦）	59.64	88.64	[47.5, 33.2, 51.4, 74.2, 91.8]
NCM（欧氏）	59.64	87.95	[49.3, 35.7, 51.8, 69.6, 91.8]

关键在第二列的差：如果瓶颈真在分类头，NCM 应该接近 task-IL 的 89，实际只有 59.6。**task-IL 89 是虚高的**——在 2 个类里做二分类，几乎任何特征空间都能做到 85+，它并不说明特征具备跨任务可比性。这条结果把诊断从“头坏了”改成“特征空间缺跨任务结构”。

5.3 特征原型约束：六组全负，且是同一个模式

表 9 原型约束六组（2 任务、8 epochs，与基线同预算）

配置	t0	t1 class-IL	旧任务	新任务	F_cil
基线	91.5	72.00	67.4	76.6	12.07
吸引 λ=0.1	94.2	71.00	63.4	78.7	15.40
吸引 λ=0.3	91.7	68.17	60.4	76.0	15.68
吸引 λ=1.0	92.7	70.00	60.1	79.9	16.28
吸引 0.05 + 铰链 0.1	90.7	70.45	65.2	75.8	12.77
铰链 0.5 / λ=1.0	93.7	71.42	65.5	77.4	14.10

三条稳定规律：约束本身**收敛**（原型损失 0.7–0.8，远低于随机 1.39；铰链能从 0.076 涨到 0.384，说明确实咬住了）→ 当前任务**一致变好** → 旧任务**一致变差**。也就是说它不是“实现没生效”，而是“生效了但方向不对”：类内吸引只把每个簇各自收紧，不约束簇与簇的相对布局，而后者才是 CIL 的瓶颈。

5.4 1:1 回放：2 任务的灵丹，5 任务的毒药

这是本项目最重要的一课。`--minibatch-size` 从项目开始一直对齐 CLS-ER 官方默认 10（每步回放 10 个旧样本，旧类只占 24% 的梯度预算）。

表 10 1:1 回放的逐检查点结果（5 任务 × 25 epochs）

预算	t0	t1	t2	t3	t4	class-IL	F_cil
24% 回放（基线）	96.1	79.0	64.1	55.2	57.5	57.51	33.49
1:1 回放	97.2	81.0	60.8	52.1	48.4	48.43	43.31

但在 2 任务、8 epochs 的快验里，同一改动是 **+5.6**（72.0 → 77.6，旧任务 67.4 → 77.0、F_cil 12.07 → 8.38），看起来像重大突破。

为什么 2 任务会骗人：只有 1 个旧任务时，32 个回放样本能均匀覆盖它（每类约 16 个），所以“提高回放权重”必然有效。任务数一多，同样的预算被摊到 4 个旧任务上，**每个旧类每步只剩 2–3 个样本**——信号不是变强而是变碎。证据是中间任务受害最重（t1 22.7 → 16.2、t2 31.5 → 23.2），而最老与最新的任务反而都略有提升。

5.5 一致性权重：0.75 是对的，敏感性是单向的

表 11 reg_weight 扫描（3 任务、8 epochs）

λ	t0	t1	t2（3 任务）	cons 占总损失	判定
0.3	92.7	73.9	56.06	5–10%	与 0.75 打平
0.75（默认）	92.7	71.9	55.78	6–13%	基准
1.5	89.9	66.7	50.82	—	明显更差

一致性项在默认配置下只占总损失的 6–13%，属于温和约束；往小调没有收益，往大调是悬崖。所以“照搬 ANN 的 0.75”不是问题，这条待办可以关闭。

6 一条方法论教训

把 §5.4 的观察提炼成一句可复用的结论：

在持续学习里，任务数 ≤ 2 的消融会系统性高估任何“保护旧任务”类改动的收益。

本项目在这个陷阱上花掉了约 4 小时 GPU：1:1 回放在 2 任务上给出 +5.6 的假信号，5 任务才暴露为 −9.1。同类风险也适用于一切“加强旧任务约束”的改动（原型约束、铰链、更高的 reg_weight）——它们在我们的 2 任务快验里全部看起来“有效或无害”，而 5 任务上全部为负。

7 与 CLS-ER 论文的对比

论文 Table 1 的 Seq-CIFAR-10 / Class-IL / buffer 500 一栏与本项目并列：

表 12 与论文 Table 1 的并列（Class-IL，buffer 500）

方法	class-IL	说明
GEM	26.20 ± 1.26	
FDR	28.71 ± 3.23	
iCaRL	47.55 ± 3.95	也用最近类均值
GSS	49.73 ± 4.78	

方法	class-IL	说明
ER	**57.74 ± 0.27**	**纯经验回放**
Mean-ER	70.40 ± 1.21	两记忆平均融合
DER	72.70 ± 1.36	
CLS-ER（论文）	**75.22 ± 0.71**	**论文主方法**
JOINT（上界）	92.20 ± 0.15	10 类联合训练
— 本项目 —		
ANN 口径	39.50	介于 FDR 与 iCaRL 之间
SNN 原生	**57.51**	**≈ ER（57.74）**
SNN 原生 + NCM	59.64	仍低于 Mean-ER 10.8 / CLS-ER 15.6

三处口径差异必须说明，否则这个并列会误导：

- **训练预算**：论文 50 epochs，本项目 25 epochs（省一半 GPU 时间）。
- **骨干规模**：论文 ANN ResNet-18 约 11.2 M 参数；本项目脉冲 width-32 约 2.8 M（1/4）。
- **seed**：论文为 3 seed 均值 ± 标准差，本项目为单 seed。

因此 15.6 点的差距**不能归因于脉冲架构。**要归因，缺一个同预算、同数据划分的 ANN 骨干对照——本项目没有实现它，这是最明确的一处未完成。

8 差距归因：稠密骨干对照

这是最初缺失、也是最关键的一个对照：**同参数量、同预算、同数据划分、同一套 CLS-ER 机制**，只把基底从脉冲换成稠密卷积。为此实现了 `backbone_ann.DenseResNet18`，它与脉冲骨干满足完全相同的接口（forward / features / forward_temporal），因此模型、双记忆、一致性损失、NCM、校准器全部一行未改。

表 12b 稠密对照：只换基底，其余完全相同

	脉冲	稠密 ANN	差
class-IL	**57.51**	**65.56**	**+8.05**
task-IL	88.98	92.99	+4.01
F_cil	33.49	29.60	-3.89
耗时	108 min	71 min	—
参数量	2.80 M	2.80 M（1.00×）	—

表 12c 逐检查点：差距随任务数放大

检查点	脉冲	稠密 ANN	差
t0	96.1	98.8	+2.8
t1	79.0	84.0	+5.0
t2	64.1	69.1	+5.0
t3	55.2	61.8	+6.6
t4	**57.5**	**65.6**	**+8.0**

末行 per-task：ANN `[49.9, 39.6, 64.8, 77.1, 96.6]`，脉冲 `[40.2, 31.8, 51.9, 69.8, 94.0]`——**每一个任务都高 2.6–12.9 点。**

归因公式（数字对得上）

```
论文 CLS-ER（ANN, 50 epochs）           75.22
   |  -9.66   <- 预算与配方（我们只有 25 epochs）
   v
稠密 ANN（2.80 M, 25 epochs）            65.56
   |  -8.05   <- 脉冲基底（T=4 直接编码 + 时间平均放电率读出）
   v
脉冲 SNN（其余完全相同）                 57.51
-----------------------------------------------
总差距 17.71 = 9.66（预算）+ 8.05（基底）
```

三条结论：

- **脉冲基底有真实代价，但没有想象中大**：相对差距约 12%。“脉冲网很差”的印象里，更大的一块其实来自预算不足（9.66 点）。

- **基底差距主要落在每个任务的绝对精度上**（低 2.6–12.9 点），F_cil 只差 3.9。这解释了此前八条“减少遗忘”的路线为何全部无效——**它们治的不是主要矛盾。**
- **我们的稠密 ANN 也只到 65.56**，离论文还差 9.66：这一半与脉冲无关，是 25 vs 50 epochs 加上简化掉的东西。差距有两块，块块都不小。

由此，优化方向应当从“减少遗忘”转向“提高单任务表征质量”：首推 `--time-steps 8`（SD²-SNN 复现里单任务上限 80.5 → 84.1），其次 `--width 64`（把参数提到与论文同规模的 11.2 M）。

8b 两个基底改进：T=8 与膜电位读出

表 12d 两个单变量基底改进（同 seed、同其余配置）

配置	class-IL	task-IL	F_cil	算力
放电率 T=4（基线）	57.51	88.98	33.49	1.00×
放电率 T=8	**58.80**	**90.28**	**33.27**	**2.08×**
膜电位 T=4	**57.96**	**89.37**	**33.32**	**1.23×**
（参考）稠密 ANN	65.56	92.99	29.60	0.66×

- **T=8 是本项目最好的 SNN 结果（+1.29），但要 2 倍算力**；膜电位用 1.23× 算力换 +0.45——每点收益的成本更低（0.51× vs 0.83× 算力/点），但绝对量太小。
- **一个假设被直接证伪**：曾推测“时间平均放电率的量化（T=4 时每维只有 9 个离散取值）是基底差距的主因”。实测完全连续的膜电位读出（96.3 / 57.96）与 9 档量化的放电率（96.1 / 57.51）几乎等价。**T=8 的收益来自“更多时间步 = 更多实际计算”，不是“更细的量化”。**
- **剩下约 6.3 点没有被任何“改模块”的手段触动。**它更可能来自训练动力学本身（替代梯度的偏差、固定 T 的计算深度上限），要动它属于换训练范式。

8c PLIF：把膜时间常数变成可学习（本项目最好的 SNN 结果）

固定 `tau=2` 意味着 **17 个 LIF 层用同一个时间积分尺度**——第一层（原始像素）和最后一层（抽象特征）的泄漏速度相同，这显然不合理。PLIF（Fang et al., ICCV'21）把它改成每层一个可学习标量：

```
1/tau = sigmoid(a)            # a 可学习，每层一个
v_t   = (1 - 1/tau) * v_{t-1} + x_t


# 初始化 a 使 1/tau = 0.5（等价于原来的 tau=2）
# 所以这是纯可学习化，不是换网络：只多 17 个参数
```

表 12e PLIF 的效果（同 seed、同其余配置）

配置	class-IL	task-IL	F_cil	算力	相对基线
放电率 T=4（基线）	57.51	88.98	33.49	1.00×	—
PLIF（可学习 tau）	**59.66**	**91.55**	**33.49**	**1.51×**	**+2.15**
（参考）稠密 ANN	65.56	92.99	29.60	0.66×	+8.05

- 逐检查点：**+1.7 / +3.1 / −0.1 / +2.4 / +2.2**（五个里四个为正）。
- **task-IL 也从 88.98 涨到 91.55（+2.57）**——这一点很关键：它说明改进不是“重排 logits”，而是表征质量本身变好了。
- 补回基底差距的 **27%**（2.15 / 8.05），是所有手段里收益最高的；按“每点收益的算力成本”算也优于 T=8（0.70× vs 0.83× 算力/点）。

8d 齿状回模式分离（k-WTA）：假设被证伪

诊断线索是 **task-IL 89 / class-IL 57.5**——每个任务内分得开、跨任务分不开。在数学上这就是“表征不够正交”。生物靠齿状回解决这个问题：颗粒细胞比皮层输入多一个数量级（扩张），且只有 2–5% 活跃（稀疏），于是重叠的输入得到几乎不重叠的码字。而我们的实测放电率是 **5–40%**，比生物密一个数量级。

表 12f 两版齿状回模型（都保持约 5% 的稀疏度）

配置	存活单元	t0	t1	class-IL	F_cil	算力
无稀疏（基线）	256（稠密）	96.1	79.0	57.51	33.49	1.00×
k-WTA 原地稀疏（5%）	13	94.2	77.4	56.37	32.75	1.13×
齿状回：4× 扩张 + 5% 稀疏	**51**	**95.6**	**78.8**	**57.41**	**33.29**	**1.57×**

- **扩张修好了“信息量”这一半**：原地稀疏到 13 个单元时 t0 掉 1.9 点，扩张 4 倍后存活 51 个单元，t0 只掉 0.5 点——代价随存活数单调减小（13→56.37，51→57.41，256→57.51）。
- **但“正交性收益”始终没有出现**：两版的 F_cil 只比基线好 0.2–0.7，在噪声内；class-IL 更是一直持平或略低。

- **因此“表征不够正交导致跨任务混淆”这个诊断被证伪。**把码字压到 5% 稀疏（理论上两两相关性大幅下降）并没有改善 class-IL——跨任务混淆的成因不是“码字太像”，而更可能是分类器在增长的 softmax 上失效，或特征被新任务的梯度整体推走。

两个实现 bug 值得一提（都由回归测试锁住了）：读出用 `last_v.detach()` 让骨干收不到梯度（task 0 掉到 64.8）；`forward_temporal` 在扩张模式下把 256 维特征喂给了 1024 维的头（直接报形状错误）。

8e 组合 PLIF + T=8：62.73，补回基底差距的 65%

表 12g 两个改进及其组合

配置	class-IL	task-IL	F_cil	算力	相对基线
基线 T=4	57.51	88.98	33.49	1.00×	—
PLIF 单独	59.66	91.55	33.49	1.51×	+2.15
T=8 单独	58.80	90.28	33.27	2.08×	+1.29
PLIF + T=8	**62.73**	**92.07**	**30.48**	**2.10×**	**+5.22**
稠密 ANN（参考）	65.56	92.99	29.60	0.66×	+8.05

- **超可加**：2.15 + 1.29 = 3.44，而组合拿到 **5.22**，多出 1.8 点的协同。机制上讲得通——PLIF 让每层找到合适的时间尺度，T=8 提供更多时间步；**有了合适的 τ，多出来的时间步才用得上。**
- **PLIF 在这个组合里几乎免费**：T=8 单独 225 分钟，组合 227 分钟。17 个标量参数、2 分钟开销，换来 3.9 点。

中间任务的改善是关键（下表左半为 class-IL，右半为末行 per-task）：

表 12h 逐检查点：t1 的 42.2 已经超过稠密 ANN 的 39.6

检查点	基线	基线 per-task	PLIF+T=8	其 per-task	ANN
t0	96.1	40.2	98.0	42.9	98.8
t1	**79.0**	**31.8**	**82.9**	**42.2**	**84.0**
t2	64.1	51.9	66.3	62.9	69.1
t3	55.2	69.8	60.2	71.1	61.8
t4	57.5	94.0	62.7	94.6	65.6

- t1 的 per-task **42.2 已经超过稠密 ANN 的 39.6**，t2 的 62.9 也接近 ANN 的 64.8。此前所有方法在 t1/t2 都只有 22–36 之间。
- F_cil 从 33.49 降到 **30.48**（ANN 29.60），遗忘也基本追平。

归因账本更新

```
论文 CLS-ER（ANN, 50ep）          75.22
  -9.66    预算/配方
我们的 ANN（25ep, 2.80M）          65.56
  -2.83    脉冲基底    <- 原本 8.05, 回 65%
我们的 SNN（PLIF + T=8）           62.73
```

“脉冲基底要付 8 点代价”这个结论被推翻了——用对架构（可学习 τ + 足够时步），代价只有 2.83 点。这同时说明前面那些“改机制”的尝试之所以无效，并不是任务本身无解，而是**改错了地方**：瓶颈在基底的训练动力学，不在持续学习的约束。

8f 固定正交分类头：同算力下最好，但与 PLIF+T=8 负交互

PS-SNN（Sci. Rep. 2026）的论点是：多数 SNN-CL 方法每个任务随机初始化分类头并用不平衡数据优化它，导致表征漂移；把可学习头换成**预先定义、固定、两两正交的类中心**就提供了稳定目标。实现只需两行：`nn.init.orthogonal_(fc.weight)` 后 `requires_grad_(False)`（`parameter_groups` 会自动跳过它，连权重衰减都碰不到）。

表 12i 固定正交头及其与 PLIF+T=8 的组合

配置	class-IL	task-IL	F_cil	算力	相对基线
基线	57.51	88.98	33.49	1.00×	—
固定正交头	**61.37**	**90.22**	**31.39**	**0.98×**	**+3.86**
三者全开（+PLIF+T=8）	61.73	90.83	32.55	2.2×	+4.22
（参考）PLIF+T=8	62.73	92.07	30.48	2.10×	+5.22

- 逐检查点（固定头）：96.7 / 82.2 / 64.9 / 59.1 / 61.4 —— **五个任务全部优于基线**，且算力与基线持平（106 vs 108 分钟）。这是本项目性价比最高的一次改动。
- **一个必须记录的弯路**：第一版照论文做 L2 归一化 + 余弦（s·cos），完全学不动（CE 卡在 log 10，预测恒为均匀）。原因是**放电率特征全部非负，而正交中心有正有负**，cos 被共同的正向分量主导，各类 logits 几乎相同。论文的设定里特征可正可负，直接搬过来不成立。现在 `--fixed-head-norm` 默认为 False。
- **负交互**：固定头 +3.86、PLIF+T=8 +5.22，相加本应 66.6，三者全开却只有 **61.73**（低于 PLIF+T=8 的 62.73）。掉的是中间任务（t1 −4.5、t2 −7.65），两头反而更好。

机制解释：两个改动治的是**同一个病**。当特征已经足够稳定（T=8 + 可学习 τ），冻结边界不再有额外好处，反而阻止边界跟随改善后的特征。**实用结论**：算力受限用固定头（+3.86，零额外算力）；追求精度用 PLIF+T=8（+5.22，2.1× 算力）。

8g 时序蒸馏：两种对齐方式都无效

脉冲网络输出的是**轨迹** $h_1 \ldots h_T$，而不是单个 logit 向量。逐时刻 KL 会把“证据晚一步出现”当成遗忘，因此另实现了可微的 **soft-DTW 轨迹对齐**（Cuturi & Blondel 2017）：它给出两条轨迹之间的最优对齐路径，允许学生把证据整体提前或推后。

表 12j 时序蒸馏的两种模式

配置	class-IL	task-IL	F_cil	相对基线
不蒸馏（基线）	57.51	88.98	33.49	—
step：逐时刻 KL（λ=0.5）	57.05	89.72	34.53	-0.46
dtw：soft-DTW（λ=0.5）	**54.70**	**87.08**	**33.03**	**-2.81**

- **两种都不行，而且 DTW 比逐时刻 KL 更差。** 这与“允许时间平移应该更好”的直觉相反。
- **λ 差 5 倍给出同一条曲线**（t1 78.2 / 78.3，t2 60.1 / 60.1），排除了“权重没调好”。
- **损伤位置固定：中间任务塌到 17–18**（基线 28.3）。中间任务既要向更新的轨迹对齐、又要向更旧的轨迹对齐，每次拉它的梯度方向都不一致。

实现上有一个必须记下的坑：soft-DTW 在两序列几乎相同时取值会低于硬最小值，**这等于给“把 logits 压小”发奖励**。修复办法是减去 teacher 与自身的距离并 clamp。单测锁住了核心性质：**时间平移 18.2 ≪ 内容改变 77.6**。

8h 补齐论文配方的四项尝试（结论被评测头推翻）

§8 把 17.7 点拆成“9.66 预算/配方 + 8.05 脉冲基底”。本节检验前半句：把四项可疑因素逐一补上（全部在**稠密 ANN** 上做，先排除脉冲干扰）。最初只看线性头时四项全为负；**换用类均值头重测后，其中两项其实是正的。**

表 12k 线性头让我们把两项正收益误判成了负收益

假设	实验	线性头	NCM	线性头的结论	修正后
基线	**ANN 2.80 M / 25ep / AdamW / reg 0.75**	**65.56**	**69.00**	**—**	**—**
① 容量 + 预算	11.2 M / 50ep	59.62	69.90	-5.94 否定	+0.90 最好
② 正则强度	同上 + reg 3.0（4×）	46.50	68.21	-13.12 灾难	-1.69 不算差
③ 优化器	2.8 M / 25ep / SGD 0.1	61.16	66.98	-4.40 否定	-2.02 略差
（对照）SNN	2.80 M / 25ep	57.51	59.64	—	—
（对照）SNN	11.2 M / 50ep	57.67	65.45	+0.16	+5.81

- **“加容量和预算是负收益”是错的**：线性头下 59.62（−5.94），类均值头下 69.90（**全场最好**）。偏置的大小和容量正相关。
- **“正则 4 倍是灾难”也是错的**：46.50 → 68.21，只比同规模基线低 1.7。
- **唯一站得住的是优化器**：SGD 0.1 在两个评测头下都比 AdamW 差约 2 点。

为什么会这样：线性头的新类偏置在“当前任务拟合得更狠”的配置上最大，而这些恰好是我们之前判定为“过拟合/灾难”的配置。类均值头不依赖 logits 的绝对尺度，所以它看到的是“特征空间里的类是否分得开”，而不是“分数有没有被压偏”。

8i 线性头在 class-IL 下不是可靠指标

同一批 checkpoint、同一个缓冲区、同一次前向——只换推理头（线性 vs 类均值），全部 25 组配置的结果如下。这一节是全文最重要的方法论发现。

表 12m 换头后 class-IL 的变化：−32.7 到 +34.2

配置	线性头	NCM	增益
ANN + 官方机制超参	55.02	67.55	+12.53
ANN + reg 3.0	46.50	68.21	+21.71
ANN @ 11.2 M / 50ep	59.62	69.90	+10.28
SNN 1:1 回放	48.43	63.93	+15.50
SNN 官方配方（train-mode 记忆）	27.44	61.67	+34.23
SNN PLIF 单独	59.66	66.42	+6.76
SNN PLIF + T=8	62.73	67.58	+4.85
SNN 基线	57.51	59.64	+2.13
SNN 固定正交头	61.37	62.37	+1.00
SNN 稳态阈值校准	**57.26**	**24.54**	**−32.72**

- **增益跨度 67 点。**这说明线性头的误差不是小扰动，而是**许多配置下的主要误差来源**——它随配置剧烈变化，因此线性头给出的排序基本不可用。
- **一个稳定的规律：线性头越差，NCM 增益越大。** 线性头的偏置集中在“当前任务拟合得更狠”的配置上。
- **它也能反向出错**：`--calibrate` 那组的 NCM 反而低 32.7 点（特征尺度被校准改坏，类均值头失效）。所以正确做法是**同时报告两个头**，而不是换一个更“好”的头。

给后续工作的建议：任何 SNN-CIL 的消融都应该同时报告线性头与类均值头。本文自己就是现成的反例——只看线性头会得出“加容量无用”“强正则有害”这类相反的结论。

8j 为什么类均值头不能拿来训练

既然类均值头评测能白拿 +2.1~4.9 点，自然的问题是：训练期就用它会怎样？两条路都试了，都失败，而且失败原因相同。

表 12n 三种分类器：只有可学习的线性头能训练

分类器	t0（2 类任务）	task 0 第 20 epoch 的 CE
线性头（基线）	**96.1**	**~0.09**
纯类均值头（`--head-mode ncm`）	53.5	log K（完全不学）
混合（`--head-mode hybrid`，辅助项 0.1）	60.0	0.70

- **根因**：`p_c = mean(f | label = c)`，损失把 `f` 推向 `p_c`、同时又让 `p_c` 跟着 `f` 走，两者互相抵消。
- **纯类均值头坍缩到** `CE = log K` **的驻点：所有特征压成一点 → 所有原型相同 → softmax 均匀** → 梯度恰好为零，**模型永远出不来。**
- **混合方案只是减慢了坍缩**：CE 项还在，但辅助项持续把同类特征往“批次均值”拉，而那是特征自己算出来的目标——等价于鼓励把同类压成一个点，t0 只有 60.0。

实现中修掉的两个问题（都不是根因，但都值得记）：

表 12o 两条失败路线的实现缺陷

问题	现象	修复
记忆用类均值头、学生用线性头	一致性项比较两种几何，cons 0.15 → 1.10	只在纯 ncm 模式下让记忆也用类均值头
新类还没进缓冲区 → 无原型 → logit 掩到 −1e4	辅助损失爆炸到 7665（loss 767）	缺失的类用当前批次的特征均值临时补上

结论：事后换头的那 2.1 点是一次性收益，不能靠“训练期换头”扩大。要让类均值头参与训练而不坍缩，需要对比学习那一套（stop-gradient + 负样本队列 + 动量编码器，SwAV/MoCo 式），那是另一个量级的工程，且与本文确认有效的主线（改基底：PLIF、时间步）方向不同。

8k 可学习发放阈值：单独有效，但与 PLIF 重叠

LIF 神经元有两个关键参数。§8c 已证明**时间常数 τ 可学习**值 +6.78；本节把阈值也变成可学习：`v_th = softplus(a_th)`，初始化使 softplus(a)=1.0（即原来的固定值），每层一个标量。`v_threshold` 做成了 property，所以阈值校准与整状态 EMA 无需改动，且可学习时参数 EMA 已覆盖它、不会平滑两遍。

表 12p 可学习阈值及其与 PLIF 的组合

配置	线性头	**类均值头**	算力	相对基线
SNN 基线	57.51	59.64	1.0×	—
可学习阈值单独	58.86	61.41	1.0×	+1.77
PLIF 单独	59.66	66.42	1.5×	+6.78
PLIF + 阈值	**60.38**	**65.86**	**1.0×**	**+6.22**
PLIF + T=8	62.73	67.58	2.1×	+7.94

- **两者不叠加**：1.77 + 6.78 的期望没有实现，实际只有 6.22——比 PLIF 单独还低 0.56。τ 决定“证据能积累多久”、v_th 决定“多少证据算够”，两者都在调放电率落在哪个区间；可学习 τ 一旦找到合适尺度，阈值只能在同一区间里微调。
- **但它把好配置的成本砍了一半**：PLIF+阈值 65.86 @ 1.8 小时，PLIF+T=8 67.58 @ 3.8 小时——**97.5% 的精度、一半算力。**
- **更重要的一点**：同样每层 17 个参数，控制**时间积分尺度**的 τ 值 +6.78，控制**发放门槛**的阈值只值 +1.77。对脉冲网络来说，**时间动态比阈值敏感一个量级。**“所有神经元参数都该可学”这句话并不成立。

8l 读出层的 4×4 → 1×1 平均：确实在丢信息

整条流水线上有一个环节从未被质疑过：layer4 输出的 4×4 脉冲图被 AdaptiveAvgPool2d(1) 平均成 256 个数，空间结构在分类头看到之前就消失了。“证据在哪里”这类信息永远不会到达分类器。

表 12q --readout-pool 的三种选择

模式	特征维度	额外参数	说明
avg	256	—	之前所有实验用的
flatten	**4096**	**+23,040**	**保留 4×4 网格**
attention	256	+257	SE 式逐样本空间门控

表 12r 保留空间网格带来 +3.14，但只有无偏分类器能看出来

配置	线性头	**类均值头**	换头增益
SNN 基线（avg）	57.51	59.64	+2.13
flatten	**58.56**	**62.78**	**+4.22**

- **全局平均确实在丢信息（+3.14）**，但线性头只看到 +1.05——因为它同时把分类头从 256 维扩到 4096 维，放大了新类偏置。换头增益从 2.13 涨到 4.22，是 §8i 那条规律（线性头系统性低估“好特征 + 大分类头”）的又一次验证。
- **单测把动机写成了断言**：两张 4×4 特征图均值相同、布局不同时，avg 池化后的结果**完全相等**，flatten 后不等。这不是“加了个开关”，而是“平均池化在原理上无法区分两种布局”的直接证明。
- **这是唯一一次“在特征之后动手”却有效的改动**——其余十几条（损失、分类器、记忆机制）全部为零或负。差别在于：它改的是**送进分类器之前**发生了什么，而不是分类器拿到特征之后做什么。

8m 所有“PLIF + 别的”组合都不如 PLIF 单独

§8k 与 §8l 各自拿到一个正收益。把 PLIF 与它们组合起来，结果全部**低于 PLIF 单独**（类均值头口径）：

表 12s 只有加时间步（T=8）能继续提升，其余两两组合都是负的

配置	线性头	**类均值头**	相对 PLIF 单独
PLIF 单独	**59.66**	**66.42**	**—**
PLIF + T=8	**62.73**	**67.58**	**+1.16**
PLIF + 可学习阈值	60.38	65.86	−0.56
PLIF + flatten 读出	60.06	65.01	−1.41
flatten 单独	58.56	62.78	(−3.64)
可学习阈值单独	58.86	61.41	(−5.01)

- **唯一的例外是时间步**：T=8 是“更多实际计算”，不是“更好的特征”——它把网络真正跑得更久，所以能和任何特征侧改动叠加。
- **为什么 flatten 与 PLIF 互斥**：flatten 把特征从 256 扩到 4096 维，而缓冲区每类只有约 50 个样本——类均值在 4096 维上的估计方差远大于 256 维。flatten 单独有效，是因为那时特征本身还弱；一旦 PLIF 把特征做好，4096 维原型估计就成了新瓶颈。
- **最优配置因此是“只开 PLIF，其余保持默认”**：架构上没有更多便宜的叠加空间，剩下的只有 T=8（+1.16，算力翻倍）和容量（对 SNN 无效，§8h）。

9 工程问题与修复

过程中定位到 6 个会直接污染实验结果的问题，均已修复并补了回归检查：

表 13 工程缺陷清单。其中 #1、#2 各自单独就让一批实验作废

#	问题	表现	修复
1	cosine 调度跨任务重启时继承 ≈0 学习率	task 1 的 CE 从 5.08 涨到 5.15，模型完全学不动	每个任务开始重置各组 lr
2	归一化特征的 EMA 原型在旋转空间里抵消	原型损失卡在 0.70 ≈ log 2，特征与自己的原型正交	改为每 epoch 从 buffer 精确重算
3	`--proto-weight 0` 时原型记忆不创建	“只开铰链”的配置静默失效，margin 恒为 0	两者任一为正即创建 + 断言
4	BiC 拟合在 `no_grad` 里跑	loss 无计算图，backward 直接报错	拟合段显式 enable_grad
5	in-place 列赋值切断计算图	反向后 logits 与参数脱钩	改 torch.where 的 out-of-place 写法
6	参数统计把两个记忆副本也算进去	显示 8.39 M（实际骨干 2.80 M）	分开报 backbone / total

10 总结论：这个架构到底什么在起作用

十几轮实验之后，最有价值的不是任何一个数字，而是一条**能把所有结果分到两边**的界线。下面按“改动的介入位置”把所有路线归类。

表 14 按介入位置分类：界线极其干净

介入位置	代表改动	结果（类均值头）	判定
特征是怎么算出来的	可学习 τ（PLIF）	66.42（+6.78）	✅ 全部为正
	时间步 T=8	67.58（+7.94）	
	保留空间网格（flatten）	62.78（+3.14）	
	可学习发放阈值	61.41（+1.77）	
特征之后做什么	固定正交头 / 1:1 回放 / WA-LA 校准	60.3 / 63.9 / 61.6	❌ 至多持平
	原型约束（六组）/ soft-DTW	≈ 基线 / 57.40	
	类均值头训练（纯 / 混合）	t0 53.5 / 60.0	
资源	宽度 64 + 50 ep（SNN）	65.45（−1.0）	⚠ 只对 ANN 有效
	同上（ANN）	69.90（+0.90）	

规律一：有效的改动全在“特征是怎么算出来的”，无效的全在“特征之后”。

四条正收益改动（τ、T、空间读出、阈值）都在改变**送进分类器之前**发生了什么；十几条零/负收益的改动（损失函数、分类头、记忆选择机制、校准）都在改变**分类器拿到特征之后**做什么。这不是巧合——脉冲网络的替代梯度有偏、时间维被平均掉、空间结构被池化掉，这三件事都在特征生成阶段，分类器再怎么设计也补不回来。

规律二：这些改动彼此替代，不是互补。

PLIF + 阈值 = 65.86（低于 PLIF 单独的 66.42）；PLIF + flatten = 65.01（低 1.41）。**唯一能叠加的是时间步**（+1.16），因为 T=8 是“真的多算”，不是“换一种算法”。这解释了为什么“再加一个 trick”的实验总是失败：它们抢的是同一个瓶颈。

规律三：评测头的选择本身能造成 67 点的差异。

线性头在 class-IL 下的新类偏置随配置从 −32.7 变到 +34.2（§8i），直接翻转了本文一半的排序——“加容量无用”“强正则有害”“1:1 回放是毒药”三个结论都是这么来的。**凡是只报单一分类头的 CIL 消融，排序都不可信。**

数字总结

```
论文 CLS-ER（官方代码，11.2 M / 50 ep）          75.22
  −5.32    我们的最佳 ANN（同模 + 类均值头）     69.90   0.8 h
```

−2.32	脉冲基底（SNN 11.2 M / 50 ep）	65.45	5.3 h
	我们的最佳 SNN（PLIF + T=8）	67.58	3.8 h
−7.94	不加任何改（SNN 基线）	59.64	1.8 h

脉冲与稠密的差距**不是常数**：裸配置 9.36 → 加 PLIF 2.58 → 再加 T=8 **1.42**。“脉冲差 8 点”只在完全没优化的配置下成立。

局限（写结论前必须承认的三条）

- **全部是单 seed。**66.42 与 67.58 只差 1.16，这个排序在单 seed 下不可靠；2 点以内的差异都不应解读。这是本文最大的短板。
- **仍不是 SOTA。**67.58 高于 ER 水平约 10 点，但低于 CLS-ER 原论文与同期 SNN-CL 工作（如 STAER）。
- **差距的成因仍未定位。**四类“补配方”尝试只解释了一小部分，剩下的 5.32 点（ANN vs 论文）来源不明。

下一步（按性价比）

- **多 seed（约 7.6 h）**：不改变架构，但决定现有排序能不能站住。这是唯一必须做的事。
- **对比学习式原型训练**（项目量级）：唯一可能突破“PLIF 单独”天花板的方向——需要 stop-gradient + 负样本队列 + 动量编码器，本文试过的纯 NCM 与混合方案都会坍缩（§8j）。
- **不要再做的**：加宽度（SNN 上 −1.0）、加 T（显存受限且递减）、以及任何“再加一个损失项/换一个分类头”的尝试（十余条全负，且有机制解释）。

附录 A 全部运行清单

表 A1 46 次训练运行（部分为快验，任务数 < 5）。此处为线性头数字；同一批 checkpoint 的类均值头结果见 §8i 与 report/head_sweep.json

run	任务数	class-IL	task-IL	F_cil	分钟
ann_ctrl	5	65.56	92.99	29.60	71
ann_e25	5	39.50	80.36	52.36	126
ann_mechfix	5	55.02	93.94	41.22	41
ann_sgd	5	61.16	91.11	34.34	38
ann_w64_e50	5	59.62	93.64	36.92	88
cal	1	42.00	42.00	0.00	1
cal_la2	2	73.92	88.28	15.53	—
cal_wala	5	54.74	90.23	37.87	153
cal_wala_noaug	3	56.55	87.53	33.63	—
nocal	1	30.40	30.40	0.00	1
proto2_w01	2	71.00	84.58	15.40	27
proto2_w03	2	68.17	82.32	15.68	17
proto2_w10	2	70.00	83.55	16.28	16
proto3_A	2	70.45	83.47	12.77	16
proto4_C	2	71.42	84.45	14.10	16
proto_check	2	59.70	78.00	18.20	13
proto_w00	2	72.00	83.75	12.07	24
proto_w01	2	29.60	58.75	29.20	24
proto_w03	1	55.45	55.45	0.00	—
reg0.15_ann_official2	5	33.42	75.61	47.88	65
reg0.15_ann_official3	5	27.44	84.58	69.86	56
reg0.3_reg03	3	56.08	83.75	28.67	33
reg075	3	55.78	84.00	28.57	29
reg1.5_reg15	3	50.82	80.68	30.60	39
reg3_ann_w64_e50_reg3	5	46.50	92.13	48.19	79
replay32	2	77.55	86.60	8.38	44
snn_all3	5	61.73	90.83	32.55	189
snn_cal	5	57.26	88.48	33.72	148
snn_dg4	5	57.41	88.89	33.29	170
snn_e25	5	57.51	88.98	33.49	108
snn_flat	5	58.56	90.23	32.77	112
snn_hybrid	1	60.00	60.00	0.00	—
snn_kwta	5	56.37	88.19	32.75	122
snn_mem2	5	57.96	89.37	33.32	133
snn_plif	5	59.66	91.55	33.49	163
snn_plif_flat	5	60.06	90.97	32.90	181
snn_plif_t8	5	62.73	92.07	30.48	227
snn_plif_vth	5	60.38	90.69	32.56	132

run	任务数	class-IL	task-IL	F_cil	分钟
snn_pshead	5	61.37	90.22	31.39	106
snn_r32	5	48.43	89.84	43.31	151
snn_t8	5	58.80	90.28	33.27	225
snn_tdist	5	57.05	89.72	34.53	125
snn_tdtw	5	54.70	87.08	33.03	146
snn_tdtw01	4	54.72	87.54	34.83	—
snn_vth	5	58.86	90.38	33.13	129
snn_w64_e50	5	57.67	91.85	37.07	315

附录 B 复现命令

```
# 主实验：SNN 原生（默配置）
python scripts/train.py --dataset seq_cifar10 --epochs 25 \
    --buffer-size 500 --batch-size 32 --width 32 --time-steps 4 --tag snn_e25


# ANN 口径（硬选择 + logits MSE + 只 EMA 参数）
python scripts/train.py ... --selector-mode hard --consistency-loss mse \
    --no-ema-buffers --tag ann_e25


# 免训练的换头对比（同权重）
python tools/eval_head_compare.py runs/seq_cifar10_T4_w32_buf500_snn_e25


# 全部结果一览
python tools/summary_table.py
python tests/smoke_test.py        # 43 项自检
```

附录 C 自检覆盖（43 项）

表 C1 tests/smoke_test.py 的覆盖范围

组	项数	内容
A CLS-ER 机制	8	脉冲前向、LIF 二值性、reservoir、硬/软选择器、EMA 调度、observe、指标、跨任务 LR 复位
B SNN 适配	6	软门控连续性与 β→∞ 极限、整状态 EMA、距离函数、编码、时序蒸馏 + 近端项、稳态阈值校准
C SD²-SNN 正则	1	分解层 / 双学习率 / Eq.18 / Eq.3 / Eq.13-14
D logit 校准	6	变换、WA 夹取、LA 边缘估计量、BiC、余弦头、任务边界重拟合
E NCM	2	原型构造与缺失类屏蔽、评测路径（含反例）
F 原型约束	4	EMA 语义、损失可优化性、refresh 修复 EMA 抵消、训练集成
G–M 基底与工程	13	稠密对照、膜电位读出与其梯度、PLIF、齿状回 k-WTA、固定正交头、断点续训、soft-DTW 对齐

组	项数	内容
N 分类头与神经元参数	3	类均值头（含未出现类屏蔽）、ncm/hybrid 训练与线性头不更新、可学习阈值（正性与梯度）
O 读出与评测	2	读出池化三模式（含 avg 无法区分布局的证明）、换头重测