CLS-ER + SD²-SNN

把互补学习系统的快慢机制移植到脉冲神经网络

六处改造 · 五条否定路线 · 一份可复现的实测记录

项目	内容
组合的两条论文线	CLS-ER（ICLR'22，互补学习系统 + 双语义记忆 + 回放） SD²-SNN（脉冲骨干、直接编码 T 步、可选结构化分解）
代码	CLS-ER+SD2-SNN（PyTorch 2.14 + CUDA 12.6，10 个模块，30 项自检）
基准	Seq-CIFAR-10（5 任务 × 2 类），buffer 500，Class-IL / Task-IL
平台	RTX 4060 Laptop 8 GB / Windows / bf16
实验量	21 次训练运行，约 14 小时 GPU
日期	2026-10-30 ~ 2026-10-31

1 摘要

本项目把 CLS-ER 的互补学习系统（双语义记忆 + 选择性一致性约束 + 回放）移植到 SD²-SNN 的脉冲骨干上，并系统回答了三个问题：哪些 ANN 机制在脉冲网络里会失效、改造后能拿回多少、以及剩下的差距在哪里。

- **六处机制必须改造**：整状态 EMA（参数 + BN 统计 + 阈值）、软门控选择器、率域温度 KL、时序蒸馏、稳态阈值校准、近端约束。直接照搬 ANN 口径只有 39.50。
- **改造后 class-IL = 57.51**（task-IL 88.98），相对 ANN 口径 **+18.0 点**。
- **进一步把基底改对（PLIF + T=8）后达到 62.73**（task-IL 92.07，F_cil 30.48），比基线高 5.22 点，与稠密 ANN 的差距从 8.05 缩到 **2.83**。
- **同算力下最好的改动是固定正交分类头（§8f）**：61.37（+3.86），算力与基线持平；但它与 PLIF+T=8 负交互——三者全开只有 61.73，低于 PLIF+T=8 的 62.73。
- **八条“减少遗忘”的路线全部为零或负**：logit 校准（三变体）、NCM 换头（+2.1，边际）、特征原型约束（六组）、1:1 回放（−9.1）、一致性权重上调（−5.0）、稳态阈值校准（−0.25）、T=8（+1.29 但 2 倍算力）、膜电位读出（+0.45）。
- **两个“更根本”的假设也被证伪**：读出量化（连续膜电位 ≈ 9 档量化）、表征正交性（齿状回 k-WTA 扩张到 51 个稀疏单元后 class-IL 仍持平）。
- **差距已可拆分**：稠密骨干对照（同参数同预算）拿到 65.56，把 17.7 点拆成 **9.66（预算/配方）+ 8.05（脉冲基底）**。基底差距落在每个任务的绝对精度上，而不是遗忘——这推翻了此前八条“减少遗忘”路线的共同前提。
- **一条方法论教训**：任务数 ≤ 2 的消融会系统性高估“保护旧任务”类改动——同一改动在 2 任务上 +5.6、在 5 任务上 −9.1。
- **与论文的差距**：我们的稠密对照也只有 65.56（论文 75.22），所以那 9.66 点与脉冲无关，来自 25 vs 50 epochs 和简化掉的配方。

2 目标与两条论文线的交接面

两个方法负责的事情是正交的，这也是移植能成立的先决条件：

表 1 两条论文线的分工

层	CLS-ER 提供	SD²-SNN 提供
学什么	working + stable/plastic 双 EMA 记忆 选择器式一致性约束（Eq.1） reservoir 回放	—
用什么学	—	LIF + ATan 替代梯度 Spiking-ResNet-18，直接编码 T 步时间平均放电率读出
可选增强	—	$W \approx UV^T$ 分解 / KL 稀疏 / 稀疏子空间（默认关闭）

于是移植的接口只有三处：输入编码、特征/放电率读出、以及“什么算一次前向”。CLS-ER 的三个模型（working / stable / plastic）共享同一套骨干结构，记忆只是权重副本。

3 六处必须改造的机制

原版 CLS-ER 的每条机制都隐含 ANN 假设，在脉冲网络里逐条失效。下表给出假设、现实、替换与证据：

表 2 六处改造（①–③ 是主实验捆绑的三项，④–⑥ 为可选）

#	原机制	ANN 隐含假设 → SNN 现实	替换为	证据
①	只 EMA 参数 W	函数只由 W 决定 → 函数由 (W, BN 统计, v_th, τ) 共同决定，BN 统计直接决定放电率尺度	整状态 EMA（参数 + buffers + 阈值）	ANN 口径下 frac_stable 前 4 任务恒 0.000
②	按真值置信度硬选记忆	softmax 置信度可靠 → T 步平均放电率方差 ~ $r(1-r)/T$	软门控 $w=\sigma(\beta\Delta c)$，$\beta\to\infty$ 退化回硬选择	低置信度区硬选择被噪声主导
③	logits 上的 MSE	logits 连续、量级稳定 → 脉冲 logits 是放电率的线性映射，量纲小且随 T 漂移	率域温度 KL + 脉冲数可靠性加权	同尺度差下 MSE 爆到 8.3、KL 有界
④	单一时刻输出	只有一个监督点 → T 个时刻各自产生证据，“何时发放”是信息	时序蒸馏（逐 timestep logits 的 KL）	ANN 无此维度，故为新增项
⑤	无活动调节	激活不会死/饱和 → 放电率会崩塌或爆炸（SNN 特有失败模式）	稳态阈值校准（homeostatic）	单任务 30.40 → 42.00（+11.6）
⑥	仅 logits 蒸馏	梯度无偏 → 代理梯度有偏，参数沿噪声方向漂移	近端约束 $\lambda\|\|\theta_W-\theta_stable\|\|^2$	可选，默认关闭

两条最硬的证据：

- **放电率**：未校准的网络在任务 0 开始几乎不发放（全网平均 0.001），校准后 0.065；学完一个任务又涨到 0.385，下个任务开始前再校准回 0.089。ANN 机制在这种情况下根本没有可用信号。
- **frac_stable**：ANN 口径下前 4 个任务恒为 0.000——stable 记忆一次都没被选中过，因为它的 BN 统计冻结在初始化副本上。整状态 EMA 之后它全程在 0.3–0.9 起伏，任务边界处升高（慢记忆接管）。

4 主实验：SNN 原生适配 vs ANN 口径

同 seed、同预算（width 32、T=4、buffer 500、batch 32、25 epochs × 5 任务），唯一差别是上表 ①②③ 的机制口径：

表 3 五任务主结果（Class-IL 为 5 个任务的平均）

配置	class-IL	task-IL	F_cil	F_til	BWT	耗时
SNN 原生	**57.51**	**88.98**	**33.49**	**3.91**	**-40.47**	**108 min**
ANN 口径	39.50	80.36	52.36	12.54	-58.02	126 min
差	+18.01	+8.62	-18.87	-8.63	17.55	—

表 4 SNN 原生的 Class-IL 矩阵（行 = 学完第 j 个任务，列 = 任务 i）

学完后	t0	t1	t2	t3	t4
t0	96.1				
t1	74.3	83.7			
t2	76.5	28.3	87.5		
t3	72.8	22.6	31.5	93.7	
t4	40.1	31.8	51.9	69.8	94.0

表 5 ANN 口径的 Class-IL 矩阵

学完后	t0	t1	t2	t3	t4
t0	96.2				
t1	66.8	83.1			
t2	68.7	14.9	89.2		
t3	62.7	7.3	5.3	96.3	
t4	23.2	32.6	19.4	27.9	94.5

三点分析：

- **单任务上限完全相同**（96.1 vs 96.2）——骨干能力一致，差异纯粹来自记忆机制。

- **差距集中在“中间任务被挤死”**：ANN 口径下 t1/t2 在学完 4 个任务后只剩 7.3 / 5.4（4 分类随机为 25%），SNN 口径保住 22.7 / 31.5；最老任务也更好（72.8 vs 62.7）。
- **task-IL 也领先 8.6 点**（89.0 vs 80.4），说明改善不只是重排 logits——整状态 EMA 让记忆真的成了一个行为自洽的慢速教师。

必须说清的局限：这一组比较的是 ①②③ 的**捆绑**，没有逐项拆开。“总共值 +18 点”是可靠的，“每项各值多少”还不知道；且只跑了单个 seed。

5 五条后续路线，全部为负

主实验之后，围绕“task-IL 89 而 class-IL 57.5 之间那 31 点”继续追，试了五条路线。每条都有明确的机制假设，每条都被实测否定。

表 6 五条路线的假设、实测与判定

路线	机制假设	实测	判定
logit 校准 (WA/LA/BiC/余弦头)	瓶颈是跨任务 logit 偏置，事后修正即可	三变体 −2.8 / −4.4 / −5.1	否定
NCM 换头 (最近类均值)	线性头无法跨任务比较，换掉它	57.51 → 59.64（+2.1）	边际
特征原型约束 (吸引 + 类间铰链)	特征缺跨任务结构，训练时加约束	六组全负（2 任务快验 −0.6 ~ −2.5）	否定
1:1 回放 (minibatch 10→32)	旧类只拿到 24% 梯度预算	2 任务 +5.6 → 5 任务 −9.1	否定
一致性权重 (0.75→1.5)	主损失权重是照搬 ANN 的	−5.0（0.3 与 0.75 打平）	否定

5.1 logit 校准：两次假设被证伪

实现了四个组件（权重对齐 WA、logit 调整 LA、偏置修正 BiC、余弦分类头），全部是 $z \to a \odot z + b$ 形式的后处理变换，不改网络、不影响记忆。

表 7 三个校准变体（2 任务、8 epochs 口径）

变体	t1 class-IL	判定	说明
基线（无校准）	79.00	—	—
WA+LA，统计量在增广样本上估	76.25	−2.75	假设：增广导致统计偏差
WA+LA，统计量在干净样本上估	74.60	−4.40	证伪：换成干净样本更差
LA，边缘均值估计器	73.92	−5.08	证伪：修正估计量后更差

两次证伪指向同一件事：问题不在“统计量估在哪儿”也不在“估计量的形式”，而在事后校正这条路本身。机理是脉冲 logits 活在放电率尺度上，该尺度随任务增加持续漂移（BN 统计、阈值都在变），静态的逐类偏置追不上这种漂移。

5.2 NCM：+2.1 点，但推翻了我的诊断

在同一个 checkpoint 上（完全相同的权重与 buffer）只换决策规则：

表 8 同权重换头的免训练对比

决策规则	class-IL	task-IL	每任务 Class-IL
线性头	57.51	88.98	[40.1, 31.8, 51.9, 69.8, 94.0]
NCM（余弦）	59.64	88.64	[47.5, 33.2, 51.4, 74.2, 91.8]
NCM（欧氏）	59.64	87.95	[49.3, 35.7, 51.8, 69.6, 91.8]

关键在第二列的差：如果瓶颈真在分类头，NCM 应该接近 task-IL 的 89，实际只有 59.6。**task-IL 89 是虚高的**——在 2 个类里做二分类，几乎任何特征空间都能做到 85+，它并不说明特征具备跨任务可比性。这条结果把诊断从“头坏了”改成“特征空间缺跨任务结构”。

5.3 特征原型约束：六组全负，且是同一个模式

表 9 原型约束六组（2 任务、8 epochs，与基线同预算）

配置	t0	t1 class-IL	旧任务	新任务	F_cil
基线	91.5	72.00	67.4	76.6	12.07
吸引 λ=0.1	94.2	71.00	63.4	78.7	15.40
吸引 λ=0.3	91.7	68.17	60.4	76.0	15.68
吸引 λ=1.0	92.7	70.00	60.1	79.9	16.28
吸引 0.05 + 铰链 0.1	90.7	70.45	65.2	75.8	12.77
铰链 0.5 / λ=1.0	93.7	71.42	65.5	77.4	14.10

三条稳定规律：约束本身**收敛**（原型损失 0.7–0.8，远低于随机 1.39；铰链能从 0.076 涨到 0.384，说明确实咬住了）→ 当前任务**一致变好** → 旧任务**一致变差**。也就是说它不是“实现没生效”，而是“生效了但方向不对”：类内吸引只把每个簇各自收紧，不约束簇与簇的相对布局，而后者才是 CIL 的瓶颈。

5.4 1:1 回放：2 任务的灵丹，5 任务的毒药

这是本项目最重要的一课。`--minibatch-size` 从项目开始一直对齐 CLS-ER 官方默认 10（每步回放 10 个旧样本，旧类只占 24% 的梯度预算）。

表 10 1:1 回放的逐检查点结果（5 任务 × 25 epochs）

预算	t0	t1	t2	t3	t4	class-IL	F_cil
24% 回放（基线）	96.1	79.0	64.1	55.2	57.5	57.51	33.49
1:1 回放	97.2	81.0	60.8	52.1	48.4	48.43	43.31

但在 2 任务、8 epochs 的快验里，同一改动是 **+5.6**（72.0 → 77.6，旧任务 67.4 → 77.0、F_cil 12.07 → 8.38），看起来像重大突破。

为什么 2 任务会骗人：只有 1 个旧任务时，32 个回放样本能均匀覆盖它（每类约 16 个），所以“提高回放权重”必然有效。任务数一多，同样的预算被摊到 4 个旧任务上，**每个旧类每步只剩 2–3 个样本**——信号不是变强而是变碎。证据是中间任务受害最重（t1 22.7 → 16.2、t2 31.5 → 23.2），而最老与最新的任务反而都略有提升。

5.5 一致性权重：0.75 是对的，敏感性是单向的

表 11 reg_weight 扫描（3 任务、8 epochs）

λ	t0	t1	t2（3 任务）	cons 占总损失	判定
0.3	92.7	73.9	56.06	5–10%	与 0.75 打平
0.75（默认）	92.7	71.9	55.78	6–13%	基准
1.5	89.9	66.7	50.82	—	明显更差

一致性项在默认配置下只占总损失的 6–13%，属于温和约束；往小调没有收益，往大调是悬崖。所以“照搬 ANN 的 0.75”不是问题，这条待办可以关闭。

6 一条方法论教训

把 §5.4 的观察提炼成一句可复用的结论：

在持续学习里，任务数 ≤ 2 的消融会系统性高估任何“保护旧任务”类改动的收益。

本项目在这个陷阱上花掉了约 4 小时 GPU：1:1 回放在 2 任务上给出 +5.6 的假信号，5 任务才暴露为 −9.1。同类风险也适用于一切“加强旧任务约束”的改动（原型约束、铰链、更高的 reg_weight）——它们在我们的 2 任务快验里全部看起来“有效或无害”，而 5 任务上全部为负。

7 与 CLS-ER 论文的对比

论文 Table 1 的 Seq-CIFAR-10 / Class-IL / buffer 500 一栏与本项目并列：

表 12 与论文 Table 1 的并列（Class-IL，buffer 500）

方法	class-IL	说明
GEM	26.20 ± 1.26	
FDR	28.71 ± 3.23	
iCaRL	47.55 ± 3.95	也用最近类均值
GSS	49.73 ± 4.78	

方法	class-IL	说明
ER	**57.74 ± 0.27**	**纯经验回放**
Mean-ER	70.40 ± 1.21	两记忆平均融合
DER	72.70 ± 1.36	
CLS-ER（论文）	**75.22 ± 0.71**	**论文主方法**
JOINT（上界）	92.20 ± 0.15	10 类联合训练
— 本项目 —		
ANN 口径	39.50	介于 FDR 与 iCaRL 之间
SNN 原生	**57.51**	**≈ ER（57.74）**
SNN 原生 + NCM	59.64	仍低于 Mean-ER 10.8 / CLS-ER 15.6

三处口径差异必须说明，否则这个并列会误导：

- **训练预算**：论文 50 epochs，本项目 25 epochs（省一半 GPU 时间）。
- **骨干规模**：论文 ANN ResNet-18 约 11.2 M 参数；本项目脉冲 width-32 约 2.8 M（1/4）。
- **seed**：论文为 3 seed 均值 ± 标准差，本项目为单 seed。

因此 15.6 点的差距**不能归因于脉冲架构。**要归因，缺一个同预算、同数据划分的 ANN 骨干对照——本项目没有实现它，这是最明确的一处未完成。

8 差距归因：稠密骨干对照

这是最初缺失、也是最关键的一个对照：**同参数量、同预算、同数据划分、同一套 CLS-ER 机制**，只把基底从脉冲换成稠密卷积。为此实现了 `backbone_ann.DenseResNet18`，它与脉冲骨干满足完全相同的接口（forward / features / forward_temporal），因此模型、双记忆、一致性损失、NCM、校准器全部一行未改。

表 12b 稠密对照：只换基底，其余完全相同

	脉冲	稠密 ANN	差
class-IL	**57.51**	**65.56**	**+8.05**
task-IL	88.98	92.99	+4.01
F_cil	33.49	29.60	-3.89
耗时	108 min	71 min	—
参数量	2.80 M	2.80 M（1.00×）	—

表 12c 逐检查点：差距随任务数放大

检查点	脉冲	稠密 ANN	差
t0	96.1	98.8	+2.8
t1	79.0	84.0	+5.0
t2	64.1	69.1	+5.0
t3	55.2	61.8	+6.6
t4	**57.5**	**65.6**	**+8.0**

末行 per-task：ANN `[49.9, 39.6, 64.8, 77.1, 96.6]`，脉冲 `[40.2, 31.8, 51.9, 69.8, 94.0]`——**每一个任务都高 2.6–12.9 点。**

归因公式（数字对得上）

```
论文 CLS-ER（ANN, 50 epochs）           75.22
   |  -9.66   <- 预算与配方（我们只有 25 epochs）
   v
稠密 ANN（2.80 M, 25 epochs）            65.56
   |  -8.05   <- 脉冲基底（T=4 直接编码 + 时间平均放电率读出）
   v
脉冲 SNN（其余完全相同）                 57.51
-----------------------------------------------
总差距 17.71 = 9.66（预算）+ 8.05（基底）
```

三条结论：

- **脉冲基底有真实代价，但没有想象中大**：相对差距约 12%。“脉冲网很差”的印象里，更大的一块其实来自预算不足（9.66 点）。

- **基底差距主要落在每个任务的绝对精度上**（低 2.6–12.9 点），F_cil 只差 3.9。这解释了此前八条“减少遗忘”的路线为何全部无效——**它们治的不是主要矛盾。**
- **我们的稠密 ANN 也只到 65.56**，离论文还差 9.66：这一半与脉冲无关，是 25 vs 50 epochs 加上简化掉的东西。差距有两块，块块都不小。

由此，优化方向应当从“减少遗忘”转向“提高单任务表征质量”：首推 `--time-steps 8`（SD²-SNN 复现里单任务上限 80.5 → 84.1），其次 `--width 64`（把参数提到与论文同规模的 11.2 M）。

8b 两个基底改进：T=8 与膜电位读出

表 12d 两个单变量基底改进（同 seed、同其余配置）

配置	class-IL	task-IL	F_cil	算力
放电率 T=4（基线）	57.51	88.98	33.49	1.00×
放电率 T=8	**58.80**	**90.28**	**33.27**	**2.08×**
膜电位 T=4	**57.96**	**89.37**	**33.32**	**1.23×**
（参考）稠密 ANN	65.56	92.99	29.60	0.66×

- **T=8 是本项目最好的 SNN 结果（+1.29），但要 2 倍算力**；膜电位用 1.23× 算力换 +0.45——每点收益的成本更低（0.51× vs 0.83× 算力/点），但绝对量太小。
- **一个假设被直接证伪**：曾推测“时间平均放电率的量化（T=4 时每维只有 9 个离散取值）是基底差距的主因”。实测完全连续的膜电位读出（96.3 / 57.96）与 9 档量化的放电率（96.1 / 57.51）几乎等价。**T=8 的收益来自“更多时间步 = 更多实际计算”，不是“更细的量化”。**
- **剩下约 6.3 点没有被任何“改模块”的手段触动。**它更可能来自训练动力学本身（替代梯度的偏差、固定 T 的计算深度上限），要动它属于换训练范式。

8c PLIF：把膜时间常数变成可学习（本项目最好的 SNN 结果）

固定 `tau=2` 意味着 **17 个 LIF 层用同一个时间积分尺度**——第一层（原始像素）和最后一层（抽象特征）的泄漏速度相同，这显然不合理。PLIF（Fang et al., ICCV'21）把它改成每层一个可学习标量：

```
1/tau = sigmoid(a)            # a 可学习，每层一个
v_t   = (1 - 1/tau) * v_{t-1} + x_t


# 初始化 a 使 1/tau = 0.5（等价于原来的 tau=2）
# 所以这是纯可学习化，不是换网络：只多 17 个参数
```

表 12e PLIF 的效果（同 seed、同其余配置）

配置	class-IL	task-IL	F_cil	算力	相对基线
放电率 T=4（基线）	57.51	88.98	33.49	1.00×	—
PLIF（可学习 tau）	**59.66**	**91.55**	**33.49**	**1.51×**	**+2.15**
（参考）稠密 ANN	65.56	92.99	29.60	0.66×	+8.05

- 逐检查点：**+1.7 / +3.1 / −0.1 / +2.4 / +2.2**（五个里四个为正）。
- **task-IL 也从 88.98 涨到 91.55（+2.57）**——这一点很关键：它说明改进不是“重排 logits”，而是表征质量本身变好了。
- 补回基底差距的 **27%**（2.15 / 8.05），是所有手段里收益最高的；按“每点收益的算力成本”算也优于 T=8（0.70× vs 0.83× 算力/点）。

8d 齿状回模式分离（k-WTA）：假设被证伪

诊断线索是 **task-IL 89 / class-IL 57.5**——每个任务内分得开、跨任务分不开。在数学上这就是“表征不够正交”。生物靠齿状回解决这个问题：颗粒细胞比皮层输入多一个数量级（扩张），且只有 2–5% 活跃（稀疏），于是重叠的输入得到几乎不重叠的码字。而我们的实测放电率是 **5–40%**，比生物密一个数量级。

表 12f 两版齿状回模型（都保持约 5% 的稀疏度）

配置	存活单元	t0	t1	class-IL	F_cil	算力
无稀疏（基线）	256（稠密）	96.1	79.0	57.51	33.49	1.00×
k-WTA 原地稀疏（5%）	13	94.2	77.4	56.37	32.75	1.13×
齿状回：4× 扩张 + 5% 稀疏	**51**	**95.6**	**78.8**	**57.41**	**33.29**	**1.57×**

- **扩张修好了“信息量”这一半**：原地稀疏到 13 个单元时 t0 掉 1.9 点，扩张 4 倍后存活 51 个单元，t0 只掉 0.5 点——代价随存活数单调减小（13→56.37，51→57.41，256→57.51）。
- **但“正交性收益”始终没有出现**：两版的 F_cil 只比基线好 0.2–0.7，在噪声内；class-IL 更是一直持平或略低。

- **因此“表征不够正交导致跨任务混淆”这个诊断被证伪。**把码字压到 5% 稀疏（理论上两两相关性大幅下降）并没有改善 class-IL——跨任务混淆的成因不是“码字太像”，而更可能是分类器在增长的 softmax 上失效，或特征被新任务的梯度整体推走。

两个实现 bug 值得一提（都由回归测试锁住了）：读出用 `last_v.detach()` 让骨干收不到梯度（task 0 掉到 64.8）；`forward_temporal` 在扩张模式下把 256 维特征喂给了 1024 维的头（直接报形状错误）。

8e 组合 PLIF + T=8：62.73，补回基底差距的 65%

表 12g 两个改进及其组合

配置	class-IL	task-IL	F_cil	算力	相对基线
基线 T=4	57.51	88.98	33.49	1.00×	—
PLIF 单独	59.66	91.55	33.49	1.51×	+2.15
T=8 单独	58.80	90.28	33.27	2.08×	+1.29
PLIF + T=8	**62.73**	**92.07**	**30.48**	**2.10×**	**+5.22**
稠密 ANN（参考）	65.56	92.99	29.60	0.66×	+8.05

- **超可加**：2.15 + 1.29 = 3.44，而组合拿到 **5.22**，多出 1.8 点的协同。机制上讲得通——PLIF 让每层找到合适的时间尺度，T=8 提供更多时间步；**有了合适的 τ，多出来的时间步才用得上。**
- **PLIF 在这个组合里几乎免费**：T=8 单独 225 分钟，组合 227 分钟。17 个标量参数、2 分钟开销，换来 3.9 点。

中间任务的改善是关键（下表左半为 class-IL，右半为末行 per-task）：

表 12h 逐检查点：t1 的 42.2 已经超过稠密 ANN 的 39.6

检查点	基线	基线 per-task	PLIF+T=8	其 per-task	ANN
t0	96.1	40.2	98.0	42.9	98.8
t1	**79.0**	**31.8**	**82.9**	**42.2**	**84.0**
t2	64.1	51.9	66.3	62.9	69.1
t3	55.2	69.8	60.2	71.1	61.8
t4	57.5	94.0	62.7	94.6	65.6

- t1 的 per-task **42.2 已经超过稠密 ANN 的 39.6**，t2 的 62.9 也接近 ANN 的 64.8。此前所有方法在 t1/t2 都只有 22–36 之间。
- F_cil 从 33.49 降到 **30.48**（ANN 29.60），遗忘也基本追平。

归因账本更新

```
论文 CLS-ER（ANN, 50ep）          75.22
  -9.66    预算/配方
我们的 ANN（25ep, 2.80M）          65.56
  -2.83    脉冲基底    <- 原本 8.05, 回 65%
我们的 SNN（PLIF + T=8）           62.73
```

“脉冲基底要付 8 点代价”这个结论被推翻了——用对架构（可学习 τ + 足够时步），代价只有 2.83 点。这同时说明前面那些“改机制”的尝试之所以无效，并不是任务本身无解，而是**改错了地方**：瓶颈在基底的训练动力学，不在持续学习的约束。

8f 固定正交分类头：同算力下最好，但与 PLIF+T=8 负交互

PS-SNN（Sci. Rep. 2026）的论点是：多数 SNN-CL 方法每个任务随机初始化分类头并用不平衡数据优化它，导致表征漂移；把可学习头换成**预先定义、固定、两两正交的类中心**就提供了稳定目标。实现只需两行：`nn.init.orthogonal_(fc.weight)` 后 `requires_grad_(False)`（`parameter_groups` 会自动跳过它，连权重衰减都碰不到）。

表 12i 固定正交头及其与 PLIF+T=8 的组合

配置	class-IL	task-IL	F_cil	算力	相对基线
基线	57.51	88.98	33.49	1.00×	—
固定正交头	**61.37**	**90.22**	**31.39**	**0.98×**	**+3.86**
三者全开（+PLIF+T=8）	61.73	90.83	32.55	2.2×	+4.22
（参考）PLIF+T=8	62.73	92.07	30.48	2.10×	+5.22

- 逐检查点（固定头）：96.7 / 82.2 / 64.9 / 59.1 / 61.4 —— **五个任务全部优于基线**，且算力与基线持平（106 vs 108 分钟）。这是本项目性价比最高的一次改动。
- **一个必须记录的弯路**：第一版照论文做 L2 归一化 + 余弦（s·cos），完全学不动（CE 卡在 log 10，预测恒为均匀）。原因是**放电率特征全部非负，而正交中心有正有负**，cos 被共同的正向分量主导，各类 logits 几乎相同。论文的设定里特征可正可负，直接搬过来不成立。现在 `--fixed-head-norm` 默认为 False。
- **负交互**：固定头 +3.86、PLIF+T=8 +5.22，相加本应 66.6，三者全开却只有 **61.73**（低于 PLIF+T=8 的 62.73）。掉的是中间任务（t1 −4.5、t2 −7.65），两头反而更好。

机制解释：两个改动治的是**同一个病**。当特征已经足够稳定（T=8 + 可学习 τ），冻结边界不再有额外好处，反而阻止边界跟随改善后的特征。**实用结论**：算力受限用固定头（+3.86，零额外算力）；追求精度用 PLIF+T=8（+5.22，2.1× 算力）。

8g 时序蒸馏：两种对齐方式都无效

脉冲网络输出的是**轨迹** $h_1 \ldots h_T$，而不是单个 logit 向量。逐时刻 KL 会把“证据晚一步出现”当成遗忘，因此另实现了可微的 **soft-DTW 轨迹对齐**（Cuturi & Blondel 2017）：它给出两条轨迹之间的最优对齐路径，允许学生把证据整体提前或推后。

表 12j 时序蒸馏的两种模式

配置	class-IL	task-IL	F_cil	相对基线
不蒸馏（基线）	57.51	88.98	33.49	—
step：逐时刻 KL（λ=0.5）	57.05	89.72	34.53	-0.46
dtw：soft-DTW（λ=0.5）	**54.70**	**87.08**	**33.03**	**-2.81**

- **两种都不行，而且 DTW 比逐时刻 KL 更差。** 这与“允许时间平移应该更好”的直觉相反。
- **λ 差 5 倍给出同一条曲线**（t1 78.2 / 78.3，t2 60.1 / 60.1），排除了“权重没调好”。
- **损伤位置固定：中间任务塌到 17–18**（基线 28.3）。中间任务既要向更新的轨迹对齐、又要向更旧的轨迹对齐，每次拉它的梯度方向都不一致。

实现上有一个必须记下的坑：soft-DTW 在两序列几乎相同时取值会低于硬最小值，**这等于给“把 logits 压小”发奖励**。修复办法是减去 teacher 与自身的距离并 clamp。单测锁住了核心性质：**时间平移 18.2 ≪ 内容改变 77.6**。

8h 配方四连否：容量、预算、正则、优化器都不是答案

§8 把 17.7 点拆成“9.66 预算/配方 + 8.05 脉冲基底”。本节检验前半句：把四项可疑因素逐一补上（全部在**稠密 ANN** 上做，先排除脉冲干扰）。

表 12k 四种“补资源”的做法全部让结果变差

假设	实验	class-IL	task-IL	F_cil	结论
基线	**ANN 2.80 M / 25ep / AdamW / reg 0.75**	**65.56**	**92.99**	**29.60**	**—**
① 容量 + 预算	11.2 M / 50ep	59.62	93.64	36.92	-5.94 否定
② 正则强度	同上 + reg 3.0（4×）	46.50	92.13	48.19	-13.12 灾难
③ 优化器	2.8 M / 25ep / SGD 0.1 + wd 5e-4	61.16	91.11	34.34	-4.40 否定
（对照）SNN	2.80 M / 25ep	57.51	88.98	33.49	—
（对照）SNN	11.2 M / 50ep	57.67	91.85	37.07	+0.16（2.9× 算力）

- **四种补法全部为负。** 加容量/预算/正则都会把**早期任务推塌**（t0 从 49.9 掉到 38.5、27.6）而把最新任务推高——多出来的能力 100% 被遗忘吃掉了。
- **正则 4 倍是灾难**：class-IL 46.50，F_cil 48.19。而它在 t1 时看起来只差 0.6，损伤沿任务序列累积才暴露——这是本项目第三次因为“早期检查点正常”而误判。

一条贯穿全项目的规律：

表 12l 四种改动都只是在稳定性–可塑性权衡线上滑动

改动	旧任务	新任务	净
固定正交头	+3.2	−1.0	+3.86（早期任务）
soft-DTW 对齐	+3.85	−5.15	−0.7
强正则（reg 3.0）	+3.15	−4.35	−0.6
更大模型 + 更长训练	−8.35	+2.65	−5.94

在固定预算下，稳定性与可塑性之间是一条近似 1:1 的权衡线。 调正则、冻边界、加时序约束都只是在这条线上移动位置；**只有提升表征质量（可学习 τ、更多时间步）才能把整条线抬高。**这也意味着论文的 75.22 不能靠“补资源”复现——缺的东西仍未定位。

9 工程问题与修复

过程中定位到 6 个会直接污染实验结果的问题，均已修复并补了回归检查：

表 13 工程缺陷清单。其中 #1、#2 各自单独就让一批实验作废

#	问题	表现	修复
1	cosine 调度跨任务重启时继承 ≈0 学习率	task 1 的 CE 从 5.08 涨到 5.15，模型完全学不动	每个任务开始重置各组 lr
2	归一化特征的 EMA 原型在旋转空间里抵消	原型损失卡在 0.70 ≈ log 2，特征与自己的原型正交	改为每 epoch 从 buffer 精确重算
3	`--proto-weight 0` 时原型记忆不创建	“只开铰链”的配置静默失效，margin 恒为 0	两者任一为正即创建 + 断言
4	BiC 拟合在 `no_grad` 里跑	loss 无计算图，backward 直接报错	拟合段显式 enable_grad
5	in-place 列赋值切断计算图	反向后 logits 与参数脱钩	改 torch.where 的 out-of-place 写法
6	参数统计把两个记忆副本也算进去	显示 8.39 M（实际骨干 2.80 M）	分开报 backbone / total

10 结论与后续

已确立

- CLS-ER 的机制不能直接搬到 SNN：六处失效，改造后值 +18.0 class-IL。
- 瓶颈不在分类头（NCM +2.1）、不在目标函数（六组约束全负）、不在回放比例（1:1 为 −9.1）、不在主损失权重（0.3/0.75 打平）、也不在放电率漂移（稳态校准 5 任务上 −0.25）。
- **差距已可拆分（§8）**：17.71 点 = 9.66（预算/配方）+ 8.05（脉冲基底）。基底差距主要体现在每个任务的绝对精度（低 2.6–12.9 点），而不是遗忘。
- **两个基底改进都只值一两点（§8b）**：T=8 拿到 +1.29（2 倍算力），膜电位读出 +0.45（1.23 倍算力）。而“读出量化是主因”这个假设被直接证伪——完全连续与 9 档量化几乎等价，说明 T 的收益来自更多实际计算，而非更细的量化。
- **唯一划算的结构改进是 PLIF（§8c）**：每层学一个时间常数，只多 17 个参数，拿到 +2.15 class-IL 与 +2.57 task-IL。它同时改善了精度和表征质量。
- **两者组合达到 62.73（§8e），且超可加**：单独 2.15 + 1.29，组合 5.22。PLIF 让每层找到合适的时间尺度，T=8 提供更多时间步，**有了合适的 τ，多出来的时间步才用得上。**
- **“表征不够正交”这个诊断被证伪（§8d）**：把码字压到 5% 稀疏（并配 4 倍扩张，存活 51 个单元）之后，class-IL 仍与基线持平。跨任务混淆的成因不是码字相关，更可能是分类器在增长的 softmax 上失效、或特征被新任务梯度整体推走。

- **最重要的反转**：脉冲基底的代价不是 8.05 点，而是 **2.83 点**。之前那些“改机制”的尝试之所以全部无效，是因为改错了地方——瓶颈在基底的训练动力学（时间常数、时间步数），不在持续学习的约束。

未完成 / 下一步

- **width 64**（约 7 小时，显存有风险）：把参数从 2.8 M 提到与论文同规模的 11.2 M，是最后一个便宜的容量杠杆；最好在 PLIF+T=8 的基础上试。
- **50 epochs**（约 7 小时）：验证 9.66 点的“预算差距”里有几成只是 epochs。
- **扫** `--stable-model-alpha`**（3 组 × 20 min 快验）：α=0.999 的等效窗口只有 1000 步，而一个任务是 7800 步——记忆的“记忆长度”只有任务长度的 1/8，这是唯一没调过的核心超参。**
- **多 seed**：本项目全部是单 seed，2 点以内的差异不应解读；PLIF+T=8 的 5.22 点需要 3 seed 确认。
- **T=16**（约 7 小时）：按 T=4→8 的斜率预计再 +1 左右，收益递减，不推荐。
- **换训练范式**（ANN-SNN 转换、长 T 训练后蒸馏到 T=4）：这 6.3 点最可能的来源是替代梯度的偏差与固定 T 的计算深度上限，动它属于新项目量级。

附录 A　全部运行清单

表 A1　21 次训练运行（部分为快验，任务数 < 5）

run	任务数	class-IL	task-IL	F_cil	分钟
ann_ctrl	5	65.56	92.99	29.60	71
ann_e25	5	39.50	80.36	52.36	126
ann_sgd	5	61.16	91.11	34.34	38
ann_w64_e50	5	59.62	93.64	36.92	88
cal	1	42.00	42.00	0.00	1
cal_la2	2	73.92	88.28	15.53	—
cal_wala	5	54.74	90.23	37.87	153
cal_wala_noaug	3	56.55	87.53	33.63	—
nocal	1	30.40	30.40	0.00	1
proto2_w01	2	71.00	84.58	15.40	27
proto2_w03	2	68.17	82.32	15.68	17
proto2_w10	2	70.00	83.55	16.28	16
proto3_A	2	70.45	83.47	12.77	16
proto4_C	2	71.42	84.45	14.10	16
proto_check	2	59.70	78.00	18.20	13
proto_w00	2	72.00	83.75	12.07	24
proto_w01	2	29.60	58.75	29.20	24
proto_w03	1	55.45	55.45	0.00	—
reg0.3_reg03	3	56.08	83.75	28.67	33
reg075	3	55.78	84.00	28.57	29
reg1.5_reg15	3	50.82	80.68	30.60	39
reg3_ann_w64_e50_reg3	5	46.50	92.13	48.19	79
replay32	2	77.55	86.60	8.38	44
snn_all3	5	61.73	90.83	32.55	189
snn_cal	5	57.26	88.48	33.72	148
snn_dg4	5	57.41	88.89	33.29	170
snn_e25	5	57.51	88.98	33.49	108
snn_kwta	5	56.37	88.19	32.75	122
snn_mem2	5	57.96	89.37	33.32	133
snn_plif	5	59.66	91.55	33.49	163
snn_plif_t8	5	62.73	92.07	30.48	227
snn_pshead	5	61.37	90.22	31.39	106
snn_r32	5	48.43	89.84	43.31	151
snn_t8	5	58.80	90.28	33.27	225
snn_tdist	5	57.05	89.72	34.53	125
snn_tdtw	5	54.70	87.08	33.03	146
snn_tdtw01	4	54.72	87.54	34.83	—
snn_w64_e50	5	57.67	91.85	37.07	315

附录 B 复现命令

```
# 主实验：SNN 原生（默配置）
python scripts/train.py --dataset seq_cifar10 --epochs 25 \
    --buffer-size 500 --batch-size 32 --width 32 --time-steps 4 --tag snn_e25


# ANN 口径（硬选择 + logits MSE + 只 EMA 参数）
python scripts/train.py ... --selector-mode hard --consistency-loss mse \
    --no-ema-buffers --tag ann_e25


# 免训练的换头对比（同权重）
python tools/eval_head_compare.py runs/seq_cifar10_T4_w32_buf500_snn_e25


# 全部结果一览
python tools/summary_table.py
python tests/smoke_test.py        # 30 项自检
```

附录 C 自检覆盖（30 项）

表 C1 tests/smoke_test.py 的覆盖范围

组	项数	内容
A CLS-ER 机制	8	脉冲前向、LIF 二值性、reservoir、硬/软选择器、EMA 调度、observe、指标、跨任务 LR 复位
B SNN 适配	6	软门控连续性与 β→∞ 极限、整状态 EMA、距离函数、编码、时序蒸馏 + 近端项、稳态阈值校准
C SD²-SNN 正则	1	分解层 / 双学习率 / Eq.18 / Eq.3 / Eq.13-14
D logit 校准	6	变换、WA 夹取、LA 边缘估计量、BiC、余弦头、任务边界重拟合
E NCM	2	原型构造与缺失类屏蔽、评测路径（含反例）
F 原型约束	4	EMA 语义、损失可优化性、refresh 修复 EMA 抵消、训练集成